PROJETO 3 – DADOS

Desafio: Secretaria Executiva de Atenção Básica – Secretaria de Saúde do Recife

EMULAÇÃO DE DADOS DA ATENÇÃO PRIMÁRIA À SAÚDE PARA AS POLÍTICAS DE EQUIDADE DO RECIFE

plano de dados sintéticos calibrados em fontes oficiais e estrutura de bancos de dados baseada no PEC/e-SUS APS

Equipe 2 – Nexus Data

Projeto 3 (Prof. Lucas Farias) · Machine Learning I (Prof. Diego Bezerra)

CESAR School · 2026.2

Recife
2026

RESUMO

A Secretaria de Saúde do Recife precisa transformar os registros do Prontuário Eletrônico do Cidadão (PEC/e-SUS APS) em informação estratégica para as Políticas Municipais de Saúde Integral da População LGBTQIAPN+, da Pessoa com Deficiência e da População Negra. Hoje, essa informação é extraída manualmente, unidade por unidade, e consolidada em planilhas; a última extração completa foi feita no ano anterior, porque o método manual não se sustenta em regime contínuo. Como a Lei Geral de Proteção de Dados (LGPD) impede, por ora, o acesso do grupo aos dados nominais das equipes de Saúde da Família, este documento propõe e avalia um plano de emulação: construir bancos de dados estruturados a partir das fichas e do modelo de dados oficiais do e-SUS APS e povoá-los com registros fictícios gerados por código reprodutível, calibrado em estatísticas públicas do IBGE (Censo 2022, PNAD Contínua, PNS 2019) e do Ministério da Saúde (CNES, SISAB). O documento analisa a planilha atualmente usada pela gestão, mostra que ela é um relatório agregado e não um banco de dados, incorpora os requisitos declarados pela Secretaria na reunião de 1.º de setembro de 2026, reúne as fontes oficiais com os parâmetros já levantados para o Recife e organiza, passo a passo, os procedimentos para chegar ao banco sintético e às suas aplicações em Sistemas Gerenciadores de Banco de Dados (SGBD), inferência estatística e aprendizado de máquina. O gerador produz uma série temporal por equipe, o que sustenta o problema supervisionado de regressão exigido em Machine Learning I. Conclui-se que o plano é viável, desde que a geração seja feita por código, as relações entre variáveis sejam explicitadas, a dinâmica no tempo e os problemas de qualidade de registro sejam simulados e as limitações dos dados sintéticos sejam declaradas.

Palavras-chave: dados sintéticos; e-SUS APS; banco de dados; equidade em saúde; LGPD; aprendizado supervisionado; Recife.

SUMÁRIO

1 INTRODUÇÃO 4

2 DIAGNÓSTICO DA PLANILHA ATUAL 5

2.1 Origem dos dados: o Relatório Consolidado de Cadastro Individual 5

2.2 Mapeamento das colunas e a regra do “dado real” 5

2.3 A planilha não é um banco de dados estruturado 6

3 FUNDAMENTAÇÃO: FICHAS, MODELO DE DADOS E RELATÓRIOS DO e-SUS APS 8

3.1 A estratégia e-SUS APS, o PEC e o ciclo do registro 8

3.2 A Ficha de Cadastro Individual (FCI) 8

3.3 Demais fichas a modelar 11

4 AVALIAÇÃO DE VIABILIDADE 13

4.1 Pontos fortes da proposta 13

4.2 Condições para a viabilidade 14

4.3 Riscos principais 14

5 FONTES DE DADOS OFICIAIS E PARÂMETROS PARA O RECIFE 15

5.1 Quadro de fontes 15

5.2 Parâmetros demográficos do Recife (Censo 2022) 15

5.3 Orientação sexual e identidade de gênero 17

6 PROCEDIMENTO PASSO A PASSO 21

Etapa 0 – Alinhamento e governança 21

Etapa 1 – Levantamento de requisitos e dicionário de dados 22

Etapa 2 – Modelagem conceitual (modelo entidade-relacionamento) 22

Etapa 3 – Modelagem lógica 23

Etapa 4 – Modelagem física 23

Etapa 5 – Coleta dos parâmetros oficiais 24

Etapa 6 – Construção do gerador de dados sintéticos 25

Etapa 7 – Injeção de problemas de qualidade 26

Etapa 8 – Carga e validação 27

Etapa 9 – Camada analítica e painel 27

Etapa 10 – Aplicações: SGBD, inferência estatística e aprendizado de máquina 28

Etapa 11 – Documentação, reprodutibilidade e experimentos 29

7 CRONOGRAMA 30

8 RISCOS, LIMITAÇÕES E CONSIDERAÇÕES ÉTICAS 31

9 CONCLUSÃO 32

REFERÊNCIAS 33

APÊNDICE A – PERGUNTAS PARA A STAKEHOLDER 35

APÊNDICE B – LISTA DE VERIFICAÇÃO DA VALIDAÇÃO 36

1 INTRODUÇÃO

O município do Recife organiza a Atenção Primária à Saúde (APS) em 8 Distritos Sanitários, 141 Unidades de Saúde da Família (USF) e 384 equipes de Saúde da Família, responsáveis pelo cadastramento e acompanhamento da população. O documento de apresentação do desafio, elaborado pela Secretaria Executiva de Atenção Básica, aponta que os dados das políticas de equidade estão distribuídos em diferentes campos do PEC/e-SUS APS e dependem de extração, consolidação e análise manuais. Não há uma ferramenta automatizada para integrar, organizar e visualizar continuamente essas informações.

Na reunião de 1.º de setembro de 2026, a referência técnica das Políticas Municipais de Equidade em Saúde apresentou a planilha *(JUL–SET) 2025 Monitoramento Indicadores LGBT*, exemplo do produto que a gestão gera hoje, e declarou um conjunto de requisitos: descer a análise da unidade para a equipe, ranquear equipes por criticidade para direcionar oficinas, ver a distribuição territorial das populações de referência e acompanhar, ao longo do tempo, se as ações formativas movem os indicadores.[1] Na mesma ocasião, ficou registrado que a definição do nível de acesso aos dados depende do núcleo de informação, inovação e monitoramento da Secretaria Executiva e que, por força da LGPD (Lei n.º 13.709/2018), o grupo ainda não pode trabalhar com dados das equipes das USF. Para seguir com o projeto sem esperar essa definição, o grupo propôs:

- criar bancos de dados estruturados (SQL e Python) a partir dos modelos de relatórios e fichas usados pelas equipes;
- gerar dados fictícios de cadastros de cidadãos, atendimentos, equipes e demais entidades necessárias, com histórico mensal;
- fazer os dados gerados refletirem as estatísticas oficiais do Recife (IBGE: Censo 2022, PNAD Contínua e outras), para uso em aprendizado de máquina, num trabalho de SGBD (modelagem conceitual, lógica e física) e em inferência estatística.

Este documento tem três objetivos: (i) avaliar a viabilidade da proposta; (ii) indicar as fontes oficiais e os parâmetros já levantados; e (iii) organizar, em etapas sequenciais, os procedimentos para construir o banco de dados e o gerador de dados sintéticos. A Seção 2 analisa a planilha atual; a Seção 3 apresenta a fundamentação no e-SUS APS; a Seção 4 traz o parecer de viabilidade; a Seção 5 reúne as fontes; a Seção 6 detalha o procedimento passo a passo, incluindo o problema supervisionado de Machine Learning I; as Seções 7 e 8 tratam de cronograma, riscos e considerações éticas; e a Seção 9 conclui.

1. Os requisitos e as citações desta seção estão sistematizados no *Registro Técnico de Reunião com o Parceiro Institucional*, de 1.º de setembro de 2026, documento interno do projeto.

2 DIAGNÓSTICO DA PLANILHA ATUAL

2.1 Origem dos dados: o Relatório Consolidado de Cadastro Individual

Os números da planilha vêm do **Relatório Consolidado de Cadastro Individual** do PEC/e-SUS APS. Segundo o manual oficial (seção 8.3.2), esse relatório mostra a situação do cadastro na data limite escolhida pelo usuário, com base na Ficha de Cadastro Individual (FCI) e no aplicativo e-SUS Território. Ele agrupa as variáveis em blocos: *Dados gerais* (onde aparecem os "cidadãos ativos", isto é, os que continuam vinculados ao território, e a "saída de cidadão do cadastro"), *Identificação do cidadão* (faixa etária, sexo, raça/cor, etnia, nacionalidade) e *Informações sociodemográficas* (deficiência, orientação sexual, identidade de gênero, entre outras). O relatório pode ser filtrado por unidade, equipe e profissional e exportado em CSV ou impresso. Segundo a Secretaria, porém, o sistema não permite selecionar várias unidades de uma vez com os mesmos filtros, o que obriga a repetir a extração para cada linha da planilha.

A planilha tem uma linha por unidade (143 a 144 linhas, mais do que as 141 USF do documento do desafio) e abas para o município, para cada um dos oito Distritos Sanitários e para modalidades específicas de equipe, como a Equipe de Consultório na Rua (eCR) e outra identificada pela sigla CAI. A diferença entre 141 USF e 144 linhas provavelmente vem dessas modalidades e precisa ser conciliada com o CNES antes de fixar a estrutura territorial do banco. As capturas de tela apresentadas pela stakeholder serviram para conferir a estrutura e as fórmulas descritas a seguir, mas não são reproduzidas aqui por se tratarem de documento interno da Secretaria.

2.2 Mapeamento das colunas e a regra do "dado real"

As fórmulas foram conferidas com os valores visíveis nas capturas de tela e todas as contas fecham. Na linha 3, por exemplo, Sim + Não + Não informado = 2.613 + 4.852 + 280 = 7.745, que é o total de cidadãos ativos da unidade. Retiradas as crianças de cada categoria (113 + 988 + 31 = 1.132), sobram 6.613 pessoas, o "dado real"; dessas, 2.500 aceitaram informar a orientação sexual (37,8%), 3.864 não aceitaram (58,4%) e 249 ficaram sem registro (3,8%).

Tabela 1 – Mapa das colunas da planilha de monitoramento

Col.	Cabeçalho	Conteúdo	Origem
A	Distrito sanitário	DS I a VIII em algarismos romanos	Digitado (não existe no PEC)
B	Dia/Mês	Data da extração da linha no PEC; varia entre unidades porque a coleta não é simultânea (nas linhas capturadas, "30/06")	Digitado
C	USF	Código e nome juntos ("US 302 USF BYRON SARINHO")	Digitado
D–G	endereço, cidade, País, estado	Endereço em texto livre; cidade, país e estado constantes	Digitado

Col.	Cabeçalho	Conteúdo	Origem
H	Cidadãos Ativos	Total de cidadãos ativos da USF	PEC – Dados gerais
I	Criança cadastrada	Crianças de 0 a 10 anos contidas em H	PEC – filtro de faixa etária
J	Cidadãos Ativos / Dado real	H − I (ex.: 11.936 − 1.291 = 10.645)	Calculado
K	Orientação sexual? SIM	Contagem bruta de “Sim”	PEC
L	Criança cadastrada	Crianças contidas em K	PEC
M	SIM / Dado real	K − L (2.613 − 113 = 2.500)	Calculado
N	SIM / %	M ÷ J (2.500 ÷ 6.613 = 38%)	Calculado
O–R	NÃO, Criança, Dado real, %	Mesma lógica (4.852 − 988 = 3.864; 58,43%)	PEC + cálculo
S–U …	NÃO INFORMADO, Criança, Dado real…	Mesma lógica; as colunas seguintes repetem o esquema para identidade de gênero e outros marcadores	PEC + cálculo

Fonte: elaborado pelo grupo a partir das capturas de tela apresentadas pela stakeholder e do registro da reunião de 01/09/2026.

O padrão confirma o que a Secretaria explicou na reunião: as crianças de 0 a 10 anos saem do numerador e do denominador porque há orientação de não fazer a pergunta sobre orientação sexual e identidade de gênero nessa faixa. É uma **decisão de gestão da Secretaria**, não uma escolha do grupo, e deve entrar no banco como regra de negócio parametrizada e versionada (idade mínima elegível = 11 anos, a confirmar se os 10 anos completos estão incluídos na exclusão). Ela não deve ser confundida com o campo “Crianças de 0 a 9 anos, com quem fica?” da FCI, que trata de outro assunto.

Há um detalhe com consequência direta para o gerador: as crianças aparecem dentro das categorias Sim, Não e Não informado (113 crianças com “Sim” na linha 3). Ou seja, o PEC registra resposta para crianças, apesar da orientação. Se o gerador não produzir essas respostas, a subtração do “dado real” não poderá ser reproduzida e um tipo real de inconsistência de registro ficará de fora.

2.3 A planilha não é um banco de dados estruturado

A planilha é um relatório agregado, montado manualmente e em formato largo, feito para leitura humana; a própria Secretaria reconheceu que ela não é intuitiva para quem não participou de sua construção. A Tabela 2 resume os problemas estruturais e como o banco proposto os resolve.

Tabela 2 – Problemas estruturais da planilha e solução no banco proposto

Problema	Consequência	Solução no banco
Sem microdados: uma linha por unidade, só contagens	Impossível cruzar orientação sexual com raça/cor, idade ou deficiência (cruzamento pedido no briefing)	Tabelas de cidadãos e cadastros no nível individual
Granularidade de unidade (143–144 linhas), não de equipe (384)	A média da unidade esconde a equipe crítica, que é exatamente o que a gestão quer encontrar	Chaves CNES → INE → microárea; indicadores por equipe
Dados brutos e calculados misturados	Erros propagam; difícil auditar	Só dado bruto nas tabelas; cálculos em visões (VIEW)
Cabeçalhos duplicados e cores com significado	Perda de sentido ao exportar	Nomes únicos; dicionário de dados
Campos não atômicos (código + nome; endereço livre)	Viola a 1ª forma normal	Atributos separados e tipados
Colunas constantes (Recife, Brasil, PE)	Redundância	Tabela de município/território
Percentuais formatados de modos diferentes	Inconsistência visual e de cálculo	Percentual calculado na consulta
Data de extração diferente em cada linha	Unidades comparadas em momentos distintos	Uma data de corte por carga (tabela de parâmetros)
Período só no nome do arquivo (“JUL–SET”)	Sem série histórica; impossível avaliar o efeito das oficinas	Coluna de competência e persistência de todas as cargas
Formato largo (4 colunas novas por marcador)	Esquema cresce sem controle	Formato longo: competência, CNES, INE, marcador, categoria, n

Fonte: elaborado pelo grupo.

3 FUNDAMENTAÇÃO: FICHAS, MODELO DE DADOS E RELATÓRIOS DO e-SUS APS

3.1 A estratégia e-SUS APS, o PEC e o ciclo do registro

A estratégia e-SUS APS reúne a Coleta de Dados Simplificada (CDS, fichas em papel ou digitadas), o PEC (prontuário eletrônico usado nas unidades informatizadas) e os aplicativos móveis, como o e-SUS Território. Os dados seguem para o Sistema de Informação em Saúde para a Atenção Básica (SISAB). A estrutura e os domínios de cada ficha são publicados no **Layout e-SUS APS de Dados e Interface (LEDI APS)**, cuja versão vigente é a 8.7.0, compatível com o PEC 5.5.26 ou superior (liberada em 13/08/2026). Para a modelagem do banco, o LEDI é a referência principal: ele define os campos, os tipos e as listas de valores aceitas, o que permite emular dados com a mesma estrutura dos reais.

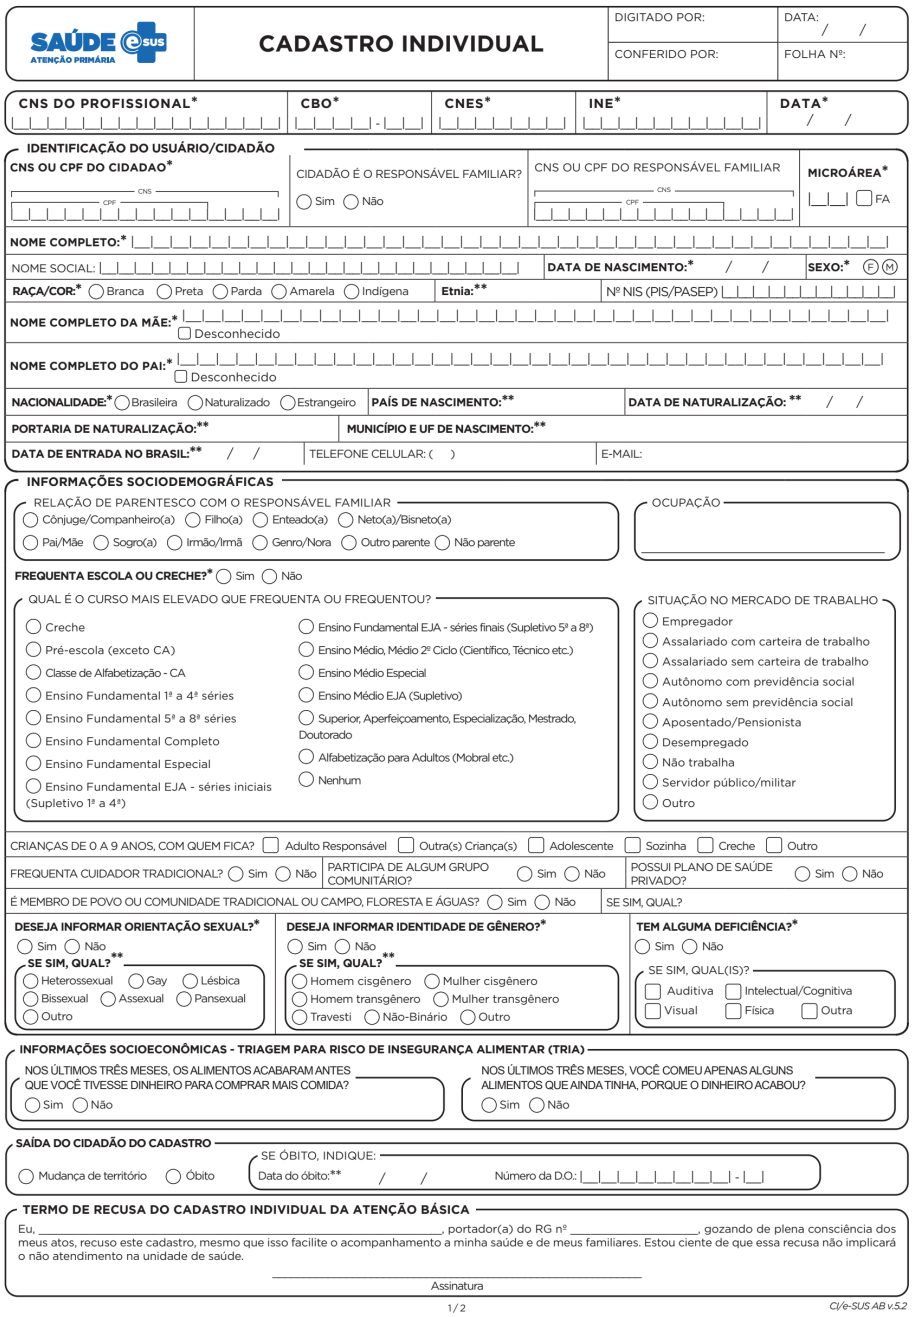
No Recife, o dado nasce no cadastro feito pelo agente comunitário de saúde no e-SUS Território, que se integra ao PEC; a partir daí, cada atendimento soma um registro ao prontuário longitudinal. A Secretaria afirmou que a rede da Atenção Básica é integralmente informatizada, com anotação em papel apenas eventual, durante visitas, e digitação posterior. A defasagem entre a data do atendimento e a data de digitação é, portanto, um fenômeno real, e o banco deve guardar as duas datas.

Duas distinções técnicas condicionam o reaproveitamento do produto com os dados reais. A primeira é o formato em que o dado chegará: exportação CSV dos relatórios, acesso ao *Data Warehouse* do PEC (esquema multidimensional documentado em integracao.esusab.ufsc.br/dw) ou extrações feitas pela própria Secretaria. O LEDI descreve a interface de envio; o que a Secretaria consegue extrair tem a forma dos relatórios ou do *Data Warehouse*. Por isso, a camada *staging* do banco sintético deve imitar o formato de entrada que for pactuado. A segunda é o tipo de instalação do PEC: uma instalação do tipo *Prontuário* guarda dado em nível de registro; uma instalação do tipo *Centralizadora* oferece dado agregado. As duas perguntas estão no Apêndice A.

3.2 A Ficha de Cadastro Individual (FCI)

A FCI concentra as variáveis exigidas pelas três políticas de equidade. A Figura 1 mostra a primeira página da ficha oficial; as Figuras 2 e 3 ampliam os blocos de identificação e de informações sociodemográficas.

Figura 1 – Ficha de Cadastro Individual do e-SUS APS (página 1)



SAÚDE e-SUS ATENÇÃO PRIMÁRIA

CADASTRO INDIVIDUAL

DIGITADO POR: | DATA: / /

CONFERIDO POR: | FOLHA Nº:

CNS DO PROFISSIONAL* | **CBO*** | **CNES*** | **INE*** | **DATA*** / /

IDENTIFICAÇÃO DO USUÁRIO/CIDADÃO

CNS OU CPF DO CIDADAO* (CNS / CPF)

CIDADÃO É O RESPONSÁVEL FAMILIAR? ◯ Sim ◯ Não

CNS OU CPF DO RESPONSÁVEL FAMILIAR (CNS / CPF)

MICROÁREA* ☐ FA

NOME COMPLETO:*

NOME SOCIAL: | **DATA DE NASCIMENTO:*** / / | **SEXO:*** (F) (M)

RAÇA/COR:* ◯ Branca ◯ Preta ◯ Parda ◯ Amarela ◯ Indígena | **Etnia:**** | Nº NIS (PIS/PASEP)

NOME COMPLETO DA MÃE:* ☐ Desconhecido

NOME COMPLETO DO PAI:* ☐ Desconhecido

NACIONALIDADE:* ◯ Brasileira ◯ Naturalizado ◯ Estrangeiro | **PAÍS DE NASCIMENTO:**** | **DATA DE NATURALIZAÇÃO:** ** / /

PORTARIA DE NATURALIZAÇÃO:** | **MUNICÍPIO E UF DE NASCIMENTO:****

DATA DE ENTRADA NO BRASIL:** / / | TELEFONE CELULAR: ( ) | E-MAIL:

INFORMAÇÕES SOCIODEMOGRÁFICAS

RELAÇÃO DE PARENTESCO COM O RESPONSÁVEL FAMILIAR

◯ Cônjuge/Companheiro(a) ◯ Filho(a) ◯ Enteado(a) ◯ Neto(a)/Bisneto(a)

◯ Pai/Mãe ◯ Sogro(a) ◯ Irmão/Irmã ◯ Genro/Nora ◯ Outro parente ◯ Não parente

OCUPAÇÃO

FREQUENTA ESCOLA OU CRECHE?* ◯ Sim ◯ Não

QUAL É O CURSO MAIS ELEVADO QUE FREQUENTA OU FREQUENTOU?

◯ Creche
◯ Pré-escola (exceto CA)
◯ Classe de Alfabetização - CA
◯ Ensino Fundamental 1ª a 4ª séries
◯ Ensino Fundamental 5ª a 8ª séries
◯ Ensino Fundamental Completo
◯ Ensino Fundamental Especial
◯ Ensino Fundamental EJA - séries iniciais (Supletivo 1ª a 4ª)
◯ Ensino Fundamental EJA - séries finais (Supletivo 5ª a 8ª)
◯ Ensino Médio, Médio 2º Ciclo (Científico, Técnico etc.)
◯ Ensino Médio Especial
◯ Ensino Médio EJA (Supletivo)
◯ Superior, Aperfeiçoamento, Especialização, Mestrado, Doutorado
◯ Alfabetização para Adultos (Mobral etc.)
◯ Nenhum

SITUAÇÃO NO MERCADO DE TRABALHO

◯ Empregador
◯ Assalariado com carteira de trabalho
◯ Assalariado sem carteira de trabalho
◯ Autônomo com previdência social
◯ Autônomo sem previdência social
◯ Aposentado/Pensionista
◯ Desempregado
◯ Não trabalha
◯ Servidor público/militar
◯ Outro

CRIANÇAS DE 0 A 9 ANOS, COM QUEM FICA? ☐ Adulto Responsável ☐ Outra(s) Criança(s) ☐ Adolescente ☐ Sozinha ☐ Creche ☐ Outro

FREQUENTA CUIDADOR TRADICIONAL? ◯ Sim ◯ Não | PARTICIPA DE ALGUM GRUPO COMUNITÁRIO? ◯ Sim ◯ Não | POSSUI PLANO DE SAÚDE PRIVADO? ◯ Sim ◯ Não

É MEMBRO DE POVO OU COMUNIDADE TRADICIONAL OU CAMPO, FLORESTA E ÁGUAS? ◯ Sim ◯ Não | SE SIM, QUAL?

DESEJA INFORMAR ORIENTAÇÃO SEXUAL?* ◯ Sim ◯ Não

SE SIM, QUAL?**
◯ Heterossexual ◯ Gay ◯ Lésbica
◯ Bissexual ◯ Assexual ◯ Pansexual
◯ Outro

DESEJA INFORMAR IDENTIDADE DE GÊNERO?* ◯ Sim ◯ Não

SE SIM, QUAL?**
◯ Homem cisgênero ◯ Mulher cisgênero
◯ Homem transgênero ◯ Mulher transgênero
◯ Travesti ◯ Não-Binário ◯ Outro

TEM ALGUMA DEFICIÊNCIA?* ◯ Sim ◯ Não

SE SIM, QUAL(IS)?
☐ Auditiva ☐ Intelectual/Cognitiva
☐ Visual ☐ Física ☐ Outra

INFORMAÇÕES SOCIOECONÔMICAS - TRIAGEM PARA RISCO DE INSEGURANÇA ALIMENTAR (TRIA)

NOS ÚLTIMOS TRÊS MESES, OS ALIMENTOS ACABARAM ANTES QUE VOCÊ TIVESSE DINHEIRO PARA COMPRAR MAIS COMIDA? ◯ Sim ◯ Não

NOS ÚLTIMOS TRÊS MESES, VOCÊ COMEU APENAS ALGUNS ALIMENTOS QUE AINDA TINHA, PORQUE O DINHEIRO ACABOU? ◯ Sim ◯ Não

SAÍDA DO CIDADÃO DO CADASTRO

◯ Mudança de território ◯ Óbito

SE ÓBITO, INDIQUE: Data do óbito:** / / Número da D.O.:

TERMO DE RECUSA DO CADASTRO INDIVIDUAL DA ATENÇÃO BÁSICA

Eu, _____, portador(a) do RG nº _____, gozando de plena consciência dos meus atos, recuso este cadastro, mesmo que isso facilite o acompanhamento a minha saúde e de meus familiares. Estou ciente de que essa recusa não implicará o não atendimento na unidade de saúde.

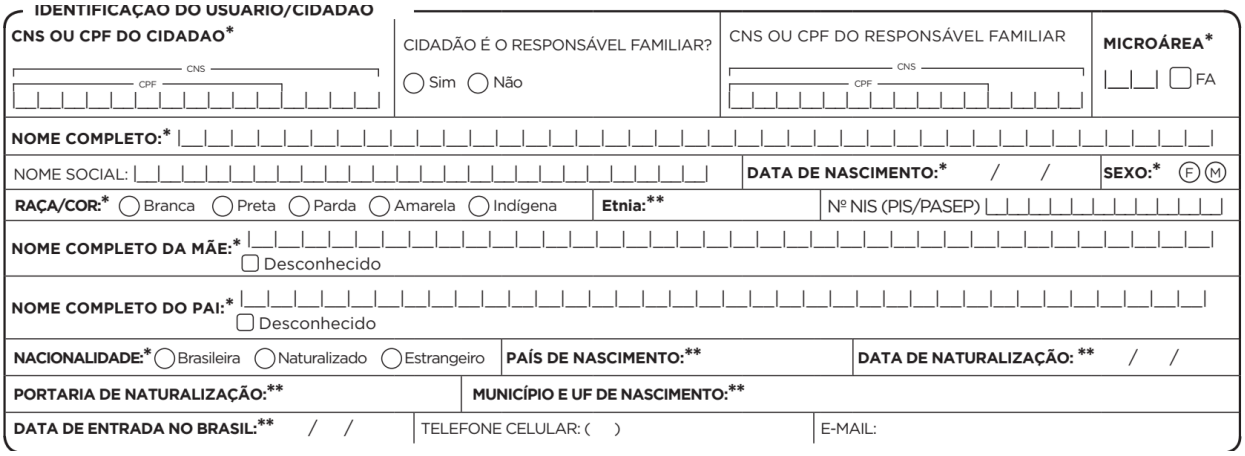
_____
Assinatura

1 / 2

CI/e-SUS AB v.5.2

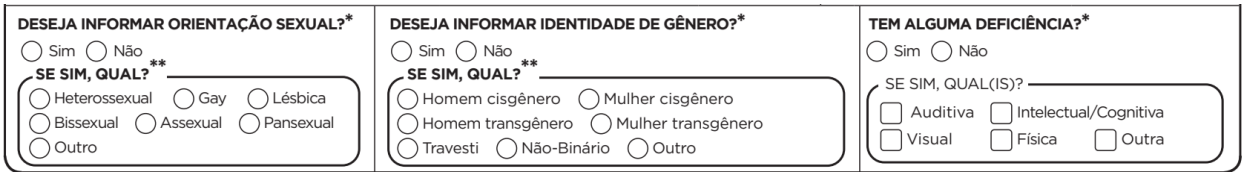
Fonte: BRASIL. Ministério da Saúde. Ficha de Cadastro Individual, CI/e-SUS AB v5.2. Disponível em: https://sisaps.saude.gov.br/esus/upload/docs/ficha_cadastro_individual.pdf. Acesso em: 15 out. 2026.

Figura 2 – FCI: bloco de identificação (CNS/CPF, nome social, sexo, raça/cor, etnia)



Fonte: recorte da Figura 1.

Figura 3 – FCI: orientação sexual, identidade de gênero e deficiência



Fonte: recorte da Figura 1.

Os quatro quesitos de equidade não se comportam da mesma forma no fluxo de cadastro. A Tabela 3 resume a assimetria, confirmada pela Secretaria na reunião de 01/09.

Tabela 3 – Comportamento dos quesitos de equidade no cadastro individual

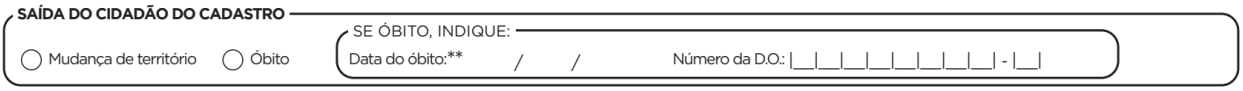
Quesito	Como o campo se comporta	O que o não preenchimento significa	Indicador primário
Raça/cor	Pergunta direta e obrigatória, categorias do IBGE (Portaria GM/MS n.º 344/2017)	Falha de registro; no fluxo atual o campo não fica vazio, e o erro típico é a categoria errada	Consistência com o perfil do território
Deficiência	Pergunta direta e obrigatória; se sim, tipo (múltipla escolha)	Falha de registro	Completude e prevalência por tipo
Orientação sexual	Precedida de “Deseja informar?”; as opções só abrem se Sim	“Não” pode ser recusa legítima; “não informado” indica que não houve registro	Proporção que aceitou informar
Identidade de gênero	Mesma lógica de consentimento prévio	Idem	Proporção que aceitou informar

Fonte: elaborado pelo grupo a partir da FCI e do registro da reunião de 01/09/2026.

Essas características têm efeito direto no modelo de dados:

- **Perguntas em dois níveis:** “Deseja informar orientação sexual?” (Sim/Não) e, se Sim, a orientação (heterossexual, gay, lésbica, bissexual, assexual, pansexual, outro). O mesmo vale para identidade de gênero (homem/mulher cisgênero, homem/mulher transgênero, travesti, não binário, outro). A pergunta é obrigatória para o profissional, mas a resposta é facultativa para o cidadão. No banco, isso vira dois atributos e permite distinguir “não quis informar” de “campo não preenchido”. A meta declarada pela Secretaria é aumentar a parcela que informa, qualquer que seja a orientação, inclusive heterossexual.
- **Os atributos pertencem à versão do cadastro, não à pessoa:** raça/cor, nome social, orientação sexual, identidade de gênero e deficiência são respostas dadas numa FCI e podem mudar na versão seguinte. Por isso ficam na tabela de cadastro, e não na de cidadão; só assim é possível representar a divergência entre versões.
- **Deficiência com múltipla escolha** (auditiva, visual, intelectual/cognitiva, física, outra): exige uma tabela associativa N:N entre cadastro e tipo de deficiência.
- **Saída do cadastro** (mudança de território ou óbito): define o status “ativo” usado no relatório.

Figura 4 – FCI: saída do cidadão do cadastro



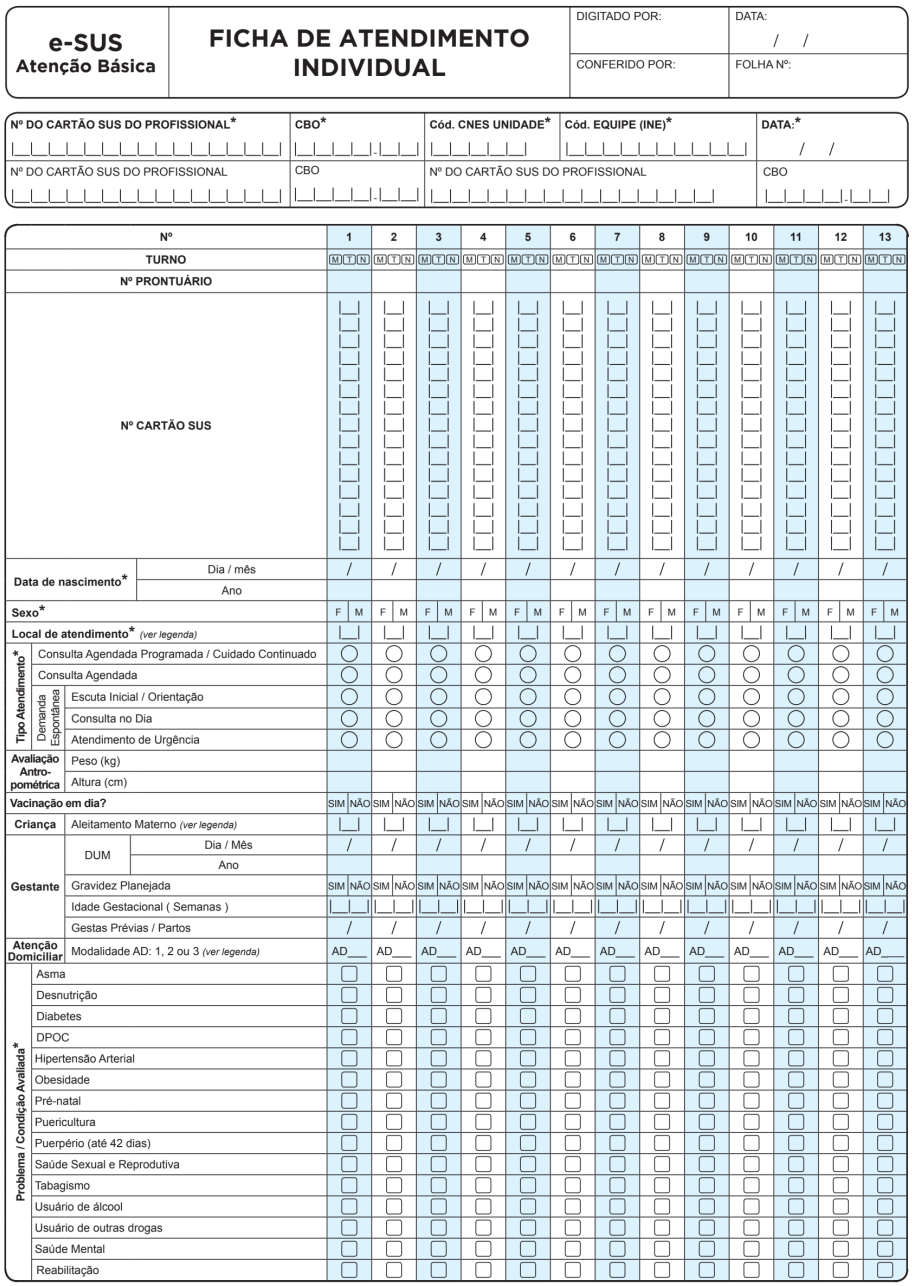
Fonte: recorte da Figura 1.

Segundo a Secretaria, o principal fator de má qualidade do registro não é a resistência do usuário, mas a insegurança do profissional, que muitas vezes não sabe como perguntar nem explicar a finalidade da pergunta. A resposta institucional são oficinas e materiais formativos. Para o gerador, isso significa que o **efeito de equipe** deve dominar a variação do registro e que as ações formativas devem existir como evento datado, capaz de mudar o comportamento da equipe.

3.3 Demais fichas a modelar

Para emular atendimentos e o vínculo territorial, o grupo deve usar também a Ficha de Atendimento Individual (FAI), que registra problema/condição avaliada (CIAP2/CID-10), e a Ficha de Cadastro Domiciliar e Territorial (FCDT), que liga domicílios e famílias à microárea. A Figura 5 mostra a FAI. Atendimentos não são necessários para o alvo principal de aprendizado de máquina (Etapa 10), mas sustentam o alvo alternativo de utilização da APS e as análises de acesso.

Figura 5 – Ficha de Atendimento Individual do e-SUS APS (página 1)



e-SUS Atenção Básica | **FICHA DE ATENDIMENTO INDIVIDUAL** | DIGITADO POR: | DATA: / / | CONFERIDO POR: | FOLHA Nº:

Nº DO CARTÃO SUS DO PROFISSIONAL*	CBO*	Cód. CNES UNIDADE*	Cód. EQUIPE (INE)*	DATA:* / /
Nº DO CARTÃO SUS DO PROFISSIONAL	CBO	Nº DO CARTÃO SUS DO PROFISSIONAL		CBO

Nº	1	2	3	4	5	6	7	8	9	10	11	12	13
TURNO	M T N	M T N	M T N	M T N	M T N	M T N	M T N	M T N	M T N	M T N	M T N	M T N	M T N
Nº PRONTUÁRIO													
Nº CARTÃO SUS													
Data de nascimento* — Dia / mês	/	/	/	/	/	/	/	/	/	/	/	/	/
Data de nascimento* — Ano													
Sexo*	F M	F M	F M	F M	F M	F M	F M	F M	F M	F M	F M	F M	F M
Local de atendimento* *(ver legenda)*													
Tipo Atendimento* — Consulta Agendada Programada / Cuidado Continuado	○	○	○	○	○	○	○	○	○	○	○	○	○
Tipo Atendimento* — Consulta Agendada	○	○	○	○	○	○	○	○	○	○	○	○	○
Tipo Atendimento* — Demanda Espontânea — Escuta Inicial / Orientação	○	○	○	○	○	○	○	○	○	○	○	○	○
Tipo Atendimento* — Demanda Espontânea — Consulta no Dia	○	○	○	○	○	○	○	○	○	○	○	○	○
Tipo Atendimento* — Demanda Espontânea — Atendimento de Urgência	○	○	○	○	○	○	○	○	○	○	○	○	○
Avaliação Antropométrica — Peso (kg)													
Avaliação Antropométrica — Altura (cm)													
Vacinação em dia?	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO
Criança — Aleitamento Materno *(ver legenda)*													
Gestante — DUM — Dia / Mês	/	/	/	/	/	/	/	/	/	/	/	/	/
Gestante — DUM — Ano													
Gestante — Gravidez Planejada	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO	SIM NÃO
Gestante — Idade Gestacional (Semanas)													
Gestante — Gestas Prévias / Partos	/	/	/	/	/	/	/	/	/	/	/	/	/
Atenção Domiciliar — Modalidade AD: 1, 2 ou 3 *(ver legenda)*	AD___	AD___	AD___	AD___	AD___	AD___	AD___	AD___	AD___	AD___	AD___	AD___	AD___
Problema / Condição Avaliada* — Asma	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Desnutrição	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Diabetes	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — DPOC	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Hipertensão Arterial	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Obesidade	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Pré-natal	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Puericultura	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Puerpério (até 42 dias)	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Saúde Sexual e Reprodutiva	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Tabagismo	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Usuário de álcool	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Usuário de outras drogas	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Saúde Mental	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
Problema / Condição Avaliada* — Reabilitação	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐

Fonte: BRASIL. Ministério da Saúde. Ficha de Atendimento Individual. Disponível em: https://si-saps.saude.gov.br/esus/upload/docs/ficha_atendimento_individual.pdf. Acesso em: 15 out. 2026.

4 AVALIAÇÃO DE VIABILIDADE

> **Parecer**
>
> O plano é viável. Ele contorna a restrição imposta pela LGPD enquanto o acesso não é pactuado e deixa o trabalho reaproveitável pela Secretaria. A viabilidade depende de seis condições, descritas em 4.2. Sem elas, o resultado seria um conjunto de dados que apenas confirma as regras que o próprio grupo programou, e não uma simulação crível, nem uma base que sustente o problema supervisionado de Machine Learning I.

4.1 Pontos fortes da proposta

- **Conformidade com a LGPD:** dados gerados a partir de distribuições agregadas não se referem a pessoa natural identificada ou identificável e, portanto, não são dados pessoais. O banco pode ser publicado, versionado e compartilhado.
- **Reaproveitamento pela gestão:** se o esquema seguir o LEDI APS e o formato de extração do PEC, a Secretaria pode, dentro da sua própria rede, apontar o mesmo pipeline e o mesmo painel para o banco real. É exatamente o produto pedido no briefing.
- **Valor didático para SGBD:** as fichas oferecem entidades claras (cidadão, domicílio, família, equipe, unidade, profissional, atendimento), relacionamentos N:N e histórico de versões de cadastro.
- **Problema supervisionado com dados disponíveis:** com histórico mensal por equipe, o banco produz um painel equipe × período com alvo conhecido, o que permite cumprir o cronograma de Machine Learning I sem depender da liberação dos dados reais.
- **Verdade conhecida:** como os parâmetros verdadeiros são conhecidos, inclusive o efeito das oficinas, é possível testar se os métodos estatísticos e de aprendizado de máquina conseguem recuperá-los.

4.2 Condições para a viabilidade

Tabela 4 – Condições para a viabilidade do plano

Condição	Justificativa	Como cumprir
1. Gerar por código, não por texto de IA	O Recife tem 1.488.920 habitantes; com atendimentos e histórico, são dezenas de milhões de registros. Linhas escritas por IA são lentas, irreprodutíveis e sem controle estatístico.	A IA ajuda a escrever o gerador em Python (numpy, Faker pt_BR), com semente fixa e fator de escala.
2. Usar dados públicos reais onde existirem	Estrutura de unidades e equipes é pública; emular o que é real empobrece o trabalho.	CNES (USF, INE), SISAB e e-Gestor (cadastros por equipe e cobertura), divisão em DS e bairros, agregados da planilha da SESAU como metas.
3. Calibrar distribuições conjuntas	Sortear variáveis de forma independente cria combinações irreais.	IPF/raking sobre cruzamentos do SIDRA; microdados da PNAD Contínua e da PNS; dependências descritas em um DAG.
4. Simular a qualidade do dado	O problema central do briefing é a qualidade do registro.	Registro em duas etapas com efeito de equipe, raça/cor em categoria errada, duplicidades, cadastros desatualizados, atraso de digitação.
5. Gerar a dinâmica no tempo	Sem série histórica não há alvo futuro para a regressão nem como avaliar as oficinas, que é uma demanda explícita da Secretaria.	Competências mensais, entradas e saídas de cadastro, tendência por equipe e ações formativas datadas com efeito conhecido.
6. Declarar as limitações	Modelos treinados em dados sintéticos aprendem as relações programadas.	Apresentar resultados como metodológicos, não epidemiológicos; fazer análise de sensibilidade.

Fonte: elaborado pelo grupo.

4.3 Riscos principais

Os maiores riscos de calibração são (a) a ausência de dados oficiais do IBGE sobre identidade de gênero e (b) a diferença entre as categorias de deficiência do Censo (perguntas do Grupo de Washington, baseadas em dificuldades funcionais) e as do e-SUS (auditiva, visual, intelectual/cognitiva, física, outra). Os dois se resolvem com premissas documentadas e testes de sensibilidade: o gerador é executado com mais de um valor para cada parâmetro incerto. Há ainda (c) uma incerteza de semântica: não se sabe se o “Não” do “Deseja informar?” registra apenas a recusa do usuário ou também casos em que a pergunta não foi feita, e (d) a indefinição sobre a forma de acesso aos dados reais, que decide o formato da camada *staging*. A Seção 8 detalha os riscos e as mitigações.

5 FONTES DE DADOS OFICIAIS E PARÂMETROS PARA O RECIFE

5.1 Quadro de fontes

Tabela 5 – Fontes oficiais recomendadas e uso no projeto

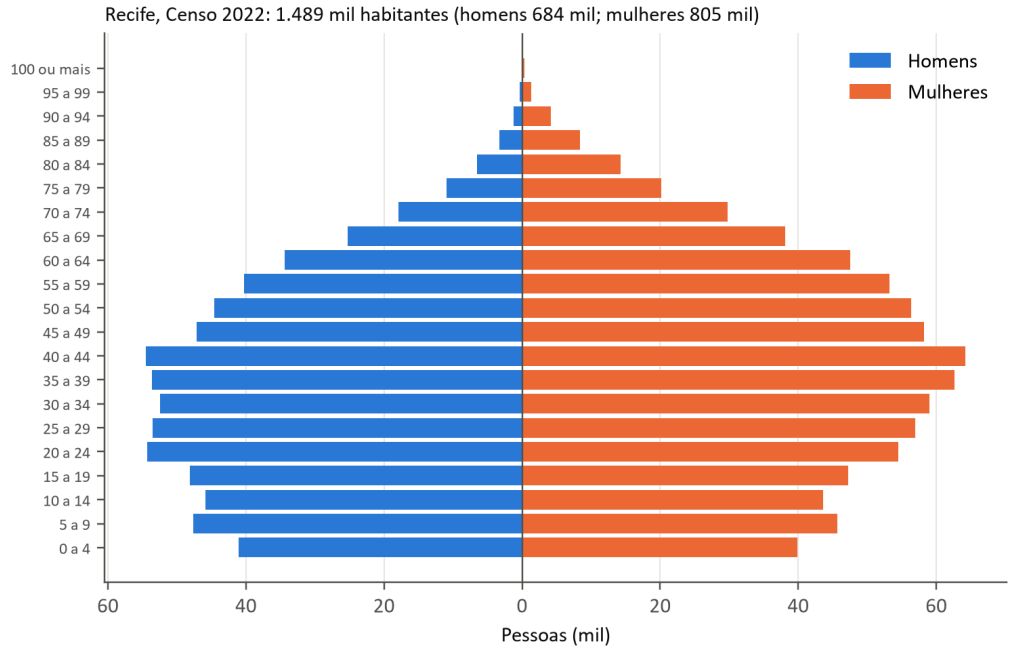
Variável / finalidade	Fonte e acesso	Observação
População, sexo, idade, cor/raça, setores censitários	IBGE – Censo 2022: SIDRA e API SIDRA (tabelas 9514, 9605)	Base demográfica; nível município e setor
Deficiência (dificuldades funcionais)	IBGE – Censo 2022, tabelas 10125, 10127, 10132 (SIDRA)	Nível municipal disponível; correspondência com e-SUS na Tabela 7
Escolaridade, renda, trabalho	IBGE – PNAD Contínua (microdados)	Variável de capital permite filtrar Recife
Orientação sexual	IBGE – PNS 2019, publicação experimental; microdados em pns.icict.fiocruz.br	Adultos de 18+; PE = 1,0%
Identidade de gênero	SPIZZIRRI et al. (2021), *Scientific Reports*	IBGE não mede; trans 0,69%, não binários 1,19%
Unidades, equipes (INE), tipos de equipe	DATASUS – CNES e arquivos de equipes no FTP do DATASUS	Estrutura real e pública; não importar nomes de profissionais
Cadastros, cobertura e produção por equipe	SISAB e e-Gestor APS	Metas de calibração por equipe; cobertura ESF (~80% segundo a Secretaria)
Estrutura das fichas e domínios	LEDI APS 8.7.0, Manual do PEC e documentação do DW do PEC	Referência do modelo ER e do formato da camada *staging*
Bairros e Distritos Sanitários	Prefeitura do Recife – portal de dados abertos (malhas territoriais)	Ligação setor censitário → bairro → DS e camada de mapa
Violência contra população LGBT	DATASUS – SINAN (campos de orientação sexual e identidade de gênero)	Opcional: indicadores de vulnerabilidade
Metas por USF	Planilha agregada da SESAU (Tabela 1)	Agregada, sem dado pessoal; pedir autorização

Fonte: elaborado pelo grupo.

5.2 Parâmetros demográficos do Recife (Censo 2022)

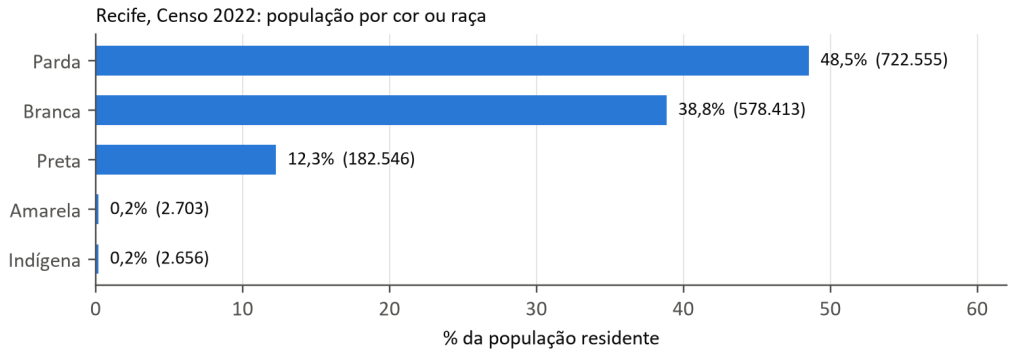
Os dados abaixo foram obtidos diretamente da API do SIDRA para o município do Recife (código IBGE 2611606). Eles já servem como marginais de calibração do gerador.

Figura 6 – Pirâmide etária do Recife, Censo 2022



Fonte: elaborado pelo grupo com dados do IBGE, Censo Demográfico 2022, tabela SIDRA 9514. Acesso em: 15 out. 2026.

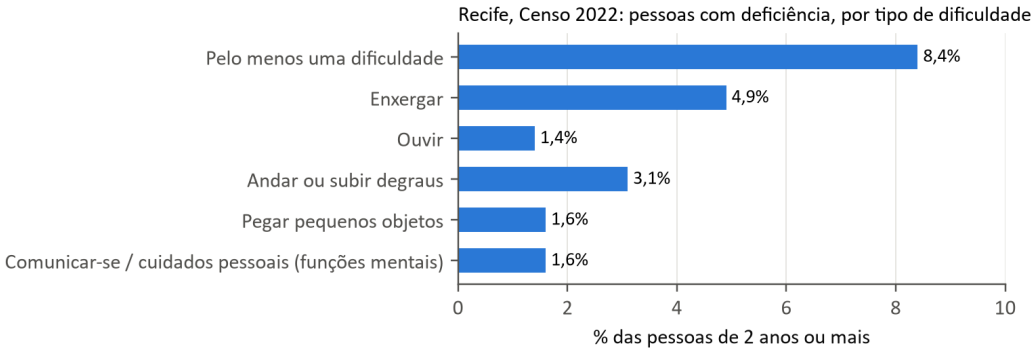
Figura 7 – População do Recife por cor ou raça, Censo 2022



Fonte: elaborado pelo grupo com dados do IBGE, Censo Demográfico 2022, tabela SIDRA 9605. Acesso em: 15 out. 2026.

Em 2022, 60,8% da população do Recife se declarou preta ou parda (12,3% preta e 48,5% parda), e 38,8%, branca. Em 2010, a proporção de pretos era de 8,3%, o que mostra a mudança na autodeclaração e reforça a importância de usar dados de 2022 na calibração. A proporção de amarelos (0,2%) é o parâmetro de referência para o caso relatado pela Secretaria de uma área com concentração anômala de registros nessa categoria.

Figura 8 – Pessoas com deficiência no Recife por tipo de dificuldade, Censo 2022



Fonte: elaborado pelo grupo com dados do IBGE, Censo Demográfico 2022, tabela SIDRA 10127. Acesso em: 15 out. 2026.

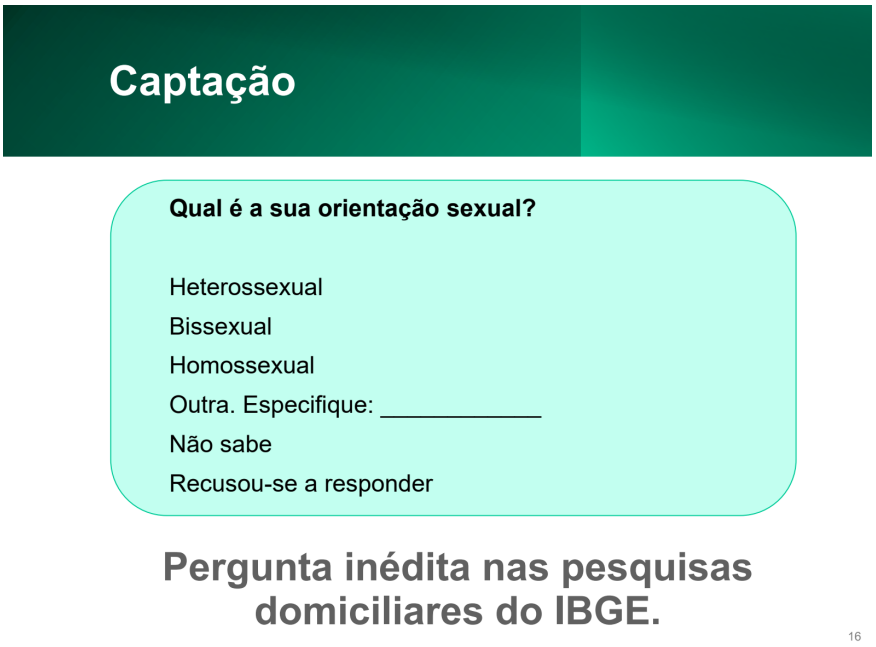
O Censo 2022 identificou 122.531 pessoas com deficiência no Recife (8,4% da população de 2 anos ou mais). Como uma pessoa pode ter mais de uma dificuldade, a soma dos tipos ultrapassa o total.

> **População residente não é população cadastrada**
>
> As marginais do Censo descrevem os residentes. O banco, porém, emula os cidadãos cadastrados e vinculados às equipes, e a cobertura da Estratégia Saúde da Família no Recife está em torno de 80%, com meta de 100%. Com 384 equipes, isso dá algo como 3 mil pessoas por equipe, ordem de grandeza compatível com o parâmetro normativo da Política Nacional de Atenção Básica. A calibração deve, portanto, ser feita por setor censitário ou bairro coberto, e o total de cadastrados deve bater com o SISAB e com a soma dos "cidadãos ativos" da planilha, e não com a população do município.

5.3 Orientação sexual e identidade de gênero

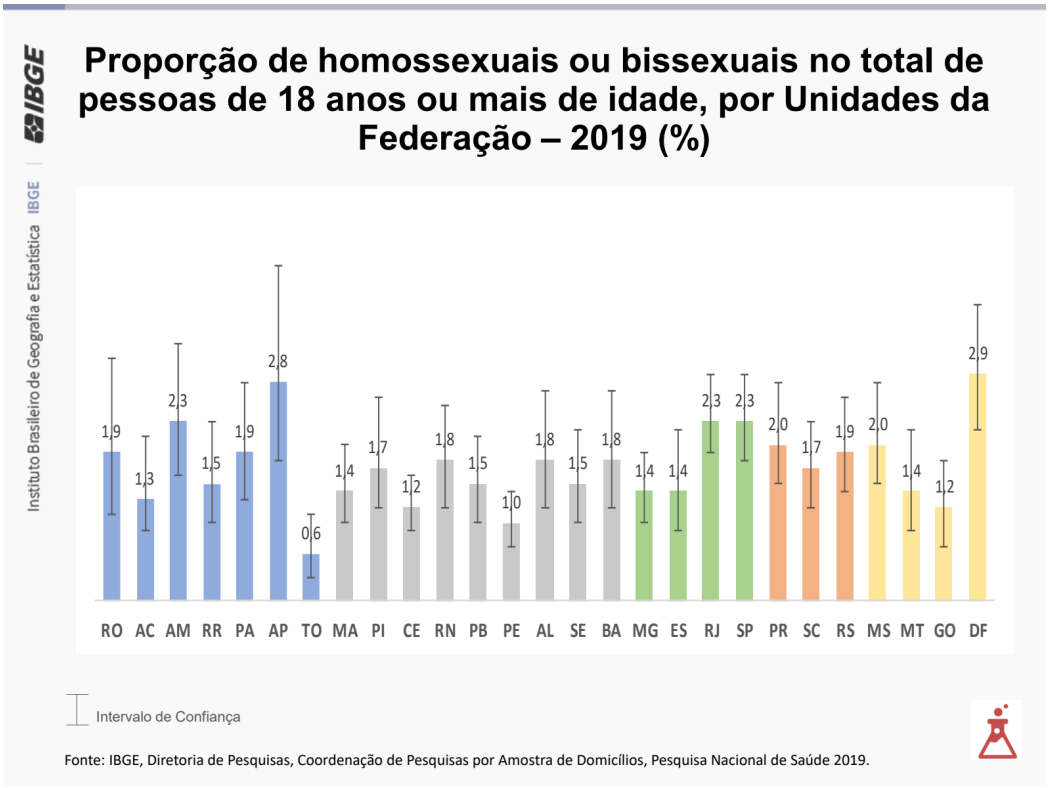
A PNS 2019 foi a primeira pesquisa domiciliar do IBGE a perguntar a orientação sexual. Os resultados são experimentais e se referem a adultos de 18 anos ou mais: 94,8% heterossexuais, 1,2% homossexuais, 0,7% bissexuais, 0,1% outra orientação, 1,1% não sabiam e 2,3% se recusaram a responder. Pernambuco teve 1,0% de homossexuais ou bissexuais, um dos menores percentuais do país (Figura 10). A proporção cai com a idade e não difere de forma significativa entre brancos, pretos e pardos (Figura 11).

Figura 9 – Pergunta sobre orientação sexual aplicada na PNS 2019



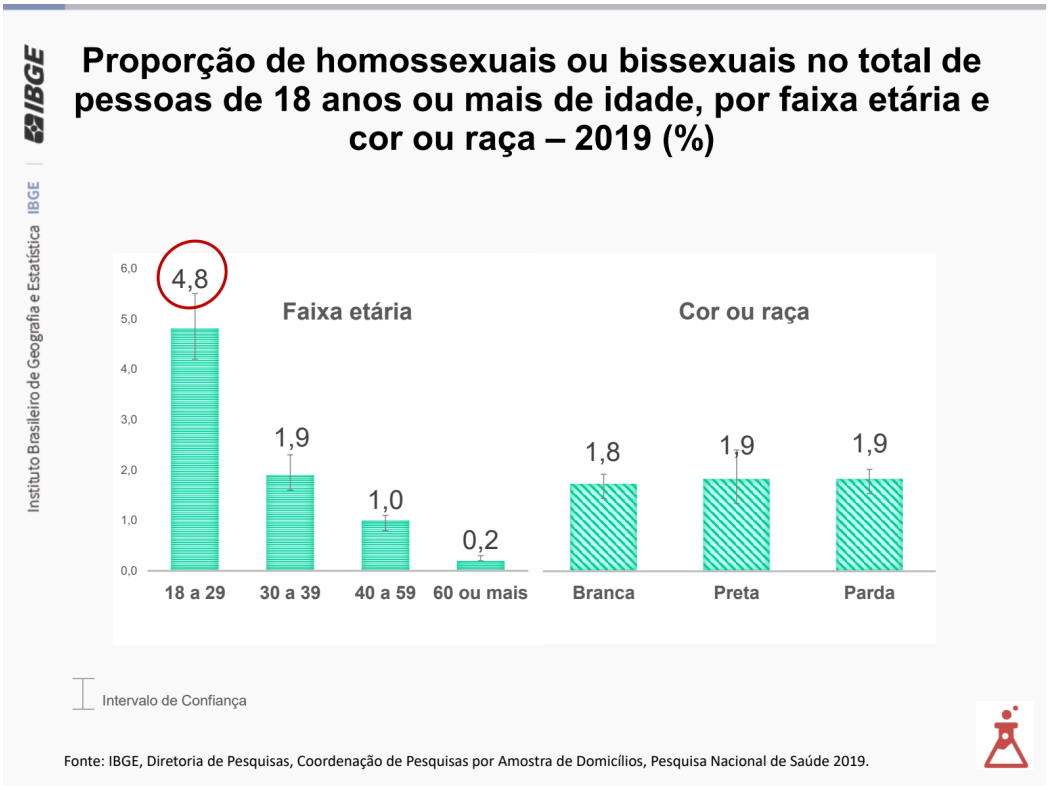
Fonte: IBGE. Orientação sexual autoidentificada da população adulta: PNS 2019. Rio de Janeiro: IBGE, 2022, p. 16.

Figura 10 – Homossexuais ou bissexuais por Unidade da Federação, PNS 2019



Fonte: IBGE. Orientação sexual autoidentificada da população adulta: PNS 2019. Rio de Janeiro: IBGE, 2022, p. 33.

Figura 11 – Homossexuais ou bissexuais por faixa etária e cor ou raça, PNS 2019



Fonte: IBGE. Orientação sexual autoidentificada da população adulta: PNS 2019. Rio de Janeiro: IBGE, 2022, p. 30.

Atenção ao usar a PNS no gerador

A amostra da PNS para o Recife é pequena. Use a taxa de Pernambuco (1,0%) ou do Nordeste como valor central e trate-a como intervalo, não como valor fixo. Lembre que a PNS mede a orientação declarada a um entrevistador do IBGE, e não a disposição de informá-la na UBS: a proporção de "Sim" para "Deseja informar?" na planilha da SESAU (de cerca de 3% a 53% conforme a USF) é a meta adequada para esse comportamento. Essa faixa é de unidade; dentro de cada unidade, a Secretaria relatou equipes muito melhores e muito piores que a média, de modo que a dispersão entre equipes deve ser maior que a dispersão entre unidades.

Para identidade de gênero, o IBGE ainda não tem dados. O estudo de Spizzirri et al. (2021), com amostra representativa de 6.000 adultos brasileiros, estimou 0,69% de pessoas transgênero (IC 95%: 0,48–0,90) e 1,19% de pessoas não binárias (IC 95%: 0,92–1,47), sem diferença entre as regiões do país.

Tabela 6 – Parâmetros iniciais sugeridos para o gerador

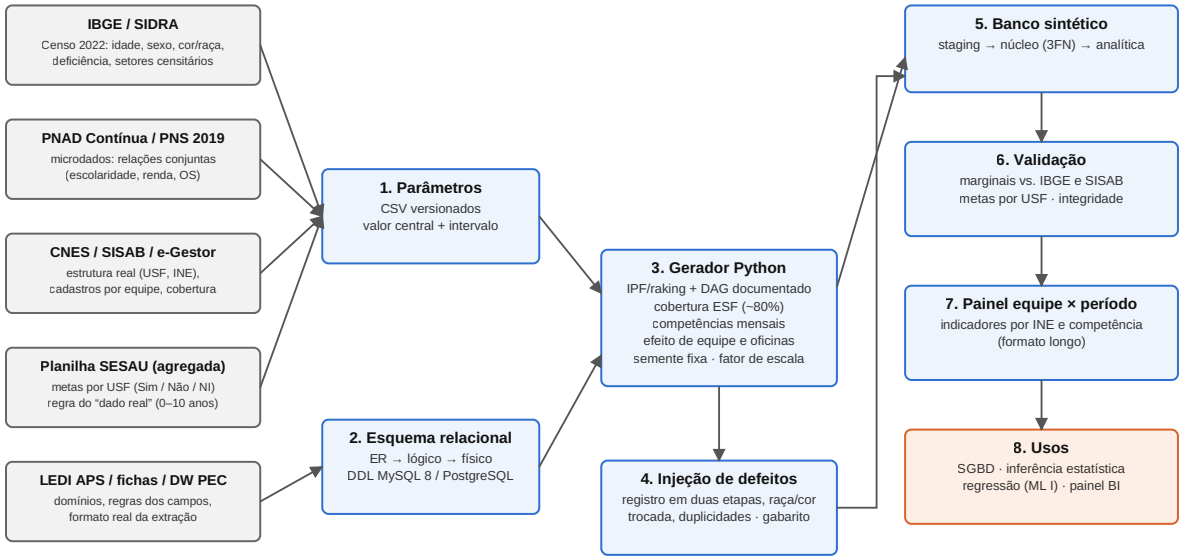
Parâmetro	Valor central	Intervalo para sensibilidade	Fonte
População total do Recife	1.488.920	fator de escala 1% a 100%	Censo 2022
Cobertura ESF (cadastrados / residentes)	~80%	75% a 90%; ajustar ao SISAB	SESAU (reunião de 01/09); SISAB
Pretos + pardos	60,8%	por setor censitário	Censo 2022
Amarelos	0,2%	por setor censitário	Censo 2022
Pessoas com deficiência (2+ anos)	8,4%	por idade e cor/raça (tab. 10125, 10132)	Censo 2022
Homossexuais ou bissexuais (18+)	1,0% (PE)	1,0% a 1,8% (PE a Brasil)	PNS 2019
Recusa / não sabe (18+)	3,4%	2% a 6%	PNS 2019
Pessoas transgênero	0,69%	0,48% a 0,90%	Spizzirri et al. (2021)
Pessoas não binárias	1,19%	0,92% a 1,47%	Spizzirri et al. (2021)
“Deseja informar OS?” = Sim (por USF)	média da planilha	de ~3% a ~53%	Planilha SESAU
Dispersão entre equipes da mesma USF	premissa	testar ao menos dois valores	SESAU (reunião de 01/09)
Idade mínima elegível para OS/IG	11 anos	10 ou 11 (limite a confirmar)	Regra do “dado real” (SESAU)
Efeito de uma oficina sobre a equipe	premissa	nulo, pequeno e moderado	Definido pelo grupo (verdade conhecida)

Fonte: elaborado pelo grupo a partir das fontes indicadas.

6 PROCEDIMENTO PASSO A PASSO

A Figura 12 mostra a visão geral do processo. Cada etapa abaixo indica objetivo, atividades e produto esperado. As etapas 1 e 2 podem correr em paralelo; as demais são sequenciais. A correspondência entre etapas e sprints da disciplina está na Seção 7.

Figura 12 – Visão geral do processo de emulação



Fonte: elaborado pelo grupo.

Etapa 0 – Alinhamento e governança

Objetivo: fechar escopo e premissas com a stakeholder e com os professores antes de modelar.

1. Levar à Secretaria apenas as perguntas ainda abertas do Apêndice A; várias foram respondidas na reunião de 01/09 (faixa etária das crianças, recorte por equipe, periodicidade).
2. Pedir autorização formal para usar a **planilha agregada** como meta de calibração (não contém dado pessoal, mas é um documento interno).
3. Definir os indicadores prioritários das três políticas (LGBTQIAPN+, pessoa com deficiência, população negra) e o recorte territorial (DS, USF, equipe, microárea).
4. Validar com o Prof. Diego Bezerra o problema supervisionado descrito na Etapa 10 (alvo, unidade de observação, partição e métricas).
5. Registrar no repositório um *termo de dados sintéticos*: os dados são fictícios, não derivam de registros reais e não podem ser apresentados como retrato da população do Recife.

Produto: documento de escopo, lista de indicadores aprovada e ficha do problema supervisionado.

Etapa 1 – Levantamento de requisitos e dicionário de dados

1. Baixar as fichas FCI, FCDT e FAI, a documentação do LEDI APS 8.7.0 e a do *Data Warehouse* do PEC.
2. Listar cada campo usado: nome, tipo, obrigatoriedade, domínio (lista de valores e códigos), regra de preenchimento condicional (ex.: orientação só se "Deseja informar" = Sim).
3. Mapear cada indicador da planilha da SESAU para os campos que o geram, incluindo a regra do "dado real".
4. Montar a tabela de correspondência entre as categorias de deficiência do IBGE e as do e-SUS (Tabela 7).

Tabela 7 – Correspondência entre dificuldades funcionais (Censo 2022) e tipos de deficiência (e-SUS)

Censo 2022 (Grupo de Washington)	e-SUS APS (FCI)	Observação
Enxergar	Visual	Correspondência direta
Ouvir	Auditiva	Correspondência direta
Andar ou subir degraus	Física	Agrupar com o item seguinte
Pegar pequenos objetos	Física	Idem
Comunicar-se / cuidados pessoais (funções mentais)	Intelectual/Cognitiva	Aproximação; documentar a premissa
—	Outra	Sem equivalente; usar pequena proporção residual

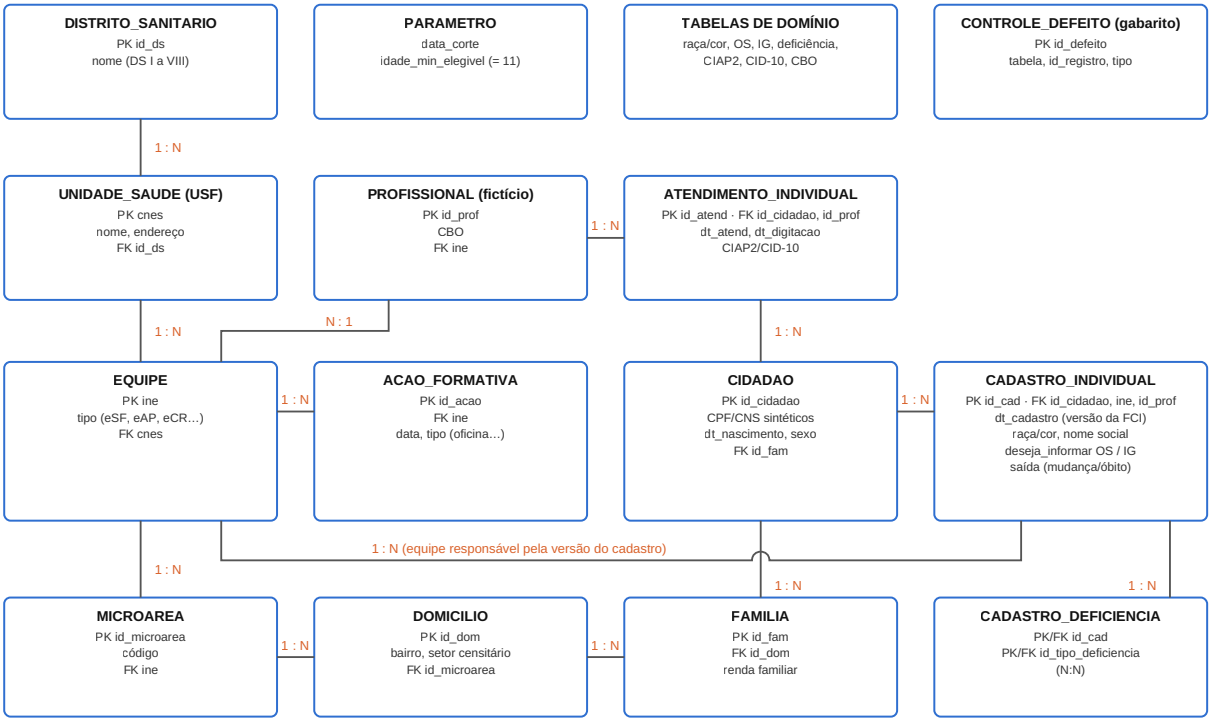
Fonte: elaborado pelo grupo com base no IBGE (Censo 2022) e na FCI.

Produto: dicionário de dados (planilha ou Markdown versionado).

Etapa 2 – Modelagem conceitual (modelo entidade-relacionamento)

Com base no dicionário, construir o modelo ER. A Figura 13 apresenta a proposta. As decisões centrais são: (i) separar cidadão (pessoa) de cadastro individual (cada versão da FCI), preservando o histórico, e guardar na versão do cadastro os atributos autodeclarados e a equipe responsável; (ii) ligar o cidadão à equipe pelo cadastro vigente na data de corte, e não por um atributo fixo da pessoa; (iii) registrar as ações formativas por equipe, para que seu efeito possa ser avaliado; (iv) manter tabelas de domínio para todos os valores codificados; e (v) manter uma tabela de parâmetros (data de corte, idade mínima elegível) e uma tabela de controle dos defeitos injetados.

Figura 13 – Modelo entidade-relacionamento conceitual proposto



Fonte: elaborado pelo grupo com base nas fichas do e-SUS APS e no LEDI APS.

Produto: diagrama ER (brModelo, draw.io ou MySQL Workbench) e descrição das regras de negócio.

Etapa 3 – Modelagem lógica

1. Converter o ER para o modelo relacional: chaves primárias, estrangeiras e tabelas associativas (ex.: *cadastro_deficiencia* para a relação N:N).
2. Normalizar até a 3ª forma normal e documentar eventuais desnormalizações da camada analítica.
3. Definir domínios e restrições: CHECK, NOT NULL, UNIQUE (CPF/CNS sintéticos), regras condicionais.
4. Organizar o banco em três camadas: **staging** (carga bruta, no formato em que o dado real chegará), **núcleo** (3FN) e **analítica** (visões e tabelas-fato para indicadores, painel e modelos).

Etapa 4 – Modelagem física

Implementar o DDL no SGBD adotado na disciplina (MySQL 8) ou em PostgreSQL, que é o SGBD usado pelo PEC. Criar índices nas colunas de filtro e junção (CNES, INE, data de cadastro) e criar as tabelas de domínio antes das que as referenciam. Para que as restrições CHECK sejam de fato aplicadas, o MySQL precisa estar na versão 8.0.16 ou superior. A Tabela 8 resume o conteúdo e as regras das tabelas do núcleo.

Tabela 8 – Tabelas do núcleo e regras principais

Tabela	Conteúdo	Chaves e restrições
Domínios (raça/cor, orientação, identidade, deficiência, CIAP2, CID-10, CBO)	Código e descrição de cada valor aceito, conforme o LEDI e as fichas	Chave primária no código; carregadas antes das demais
parametro	Data de corte da carga e idade mínima elegível para OS/IG (11 anos)	Linha única; a regra do “dado real” é lida daqui, nunca fixada em consulta
distrito_sanitario, unidade_saude, equipe	DS I a VIII; unidades com código CNES real; equipes com INE real e tipo (eSF, eAP, eCR…)	Hierarquia por chaves estrangeiras: equipe → unidade → distrito
cidadao	Atributos estáveis da pessoa: CPF e CNS sintéticos, data de nascimento, sexo	CPF e CNS únicos quando preenchidos; ao menos um dos dois obrigatório
cadastro_individual	Uma linha por versão da FCI: equipe responsável, data, raça/cor, nome social, “Deseja informar?” OS e IG, orientação, identidade, saída	Orientação só pode existir se “Deseja informar OS” = Sim; o mesmo para identidade; “Deseja informar” vazio significa não registrado; índice por cidadão e data
cadastro_deficiencia	Tipos de deficiência de cada versão do cadastro	Chave composta (cadastro, tipo): relação N:N
acao_formativa	Oficinas e materiais por equipe, com data e tipo	Chave estrangeira para equipe
atendimento_individual	Atendimentos com data do atendimento, data de digitação e CIAP2/CID-10	Chaves estrangeiras para cidadão e profissional
controle_defeito	Gabarito dos defeitos injetados: tabela, registro e tipo	Não participa dos indicadores; serve só para avaliação

Fonte: elaborado pelo grupo com base no LEDI APS e nas fichas do e-SUS APS.

Duas escolhas merecem nota. A unicidade de CPF e CNS sintéticos é mantida: a duplicidade realista no PEC não é o mesmo CPF repetido, mas a mesma pessoa cadastrada duas vezes com identificadores diferentes (um registro com CPF, outro só com CNS, nome com grafia variada). E raça/cor fica na versão do cadastro, o que permite representar a divergência entre versões.

Produto: script DDL, script de carga de domínios e documentação física (tipos, índices, volumes estimados).

Etapa 5 – Coleta dos parâmetros oficiais

1. Baixar do SIDRA as marginais do Recife (Tabelas 9514, 9605, 10125, 10127, 10132) e, se possível, por setor censitário.
2. Baixar a estrutura de USF e equipes do CNES, a contagem de cadastros por equipe e a cobertura do SISAB e do e-Gestor APS, e conciliar com as 143–144 linhas da planilha.

3. Processar os microdados da PNAD Contínua (filtro de capital = Recife) e da PNS 2019 (orientação sexual).
4. Salvar todos os parâmetros em CSV versionados, com fonte, data de acesso e intervalo de incerteza.

A coleta das marginais do Censo é feita por script, pela API pública do SIDRA, informando a tabela, o município (código 2611606), o ano e a classificação desejada; o resultado é gravado diretamente no CSV de parâmetros. Foi assim que se obtiveram os dados das Figuras 6 a 8, e essa coleta automática corresponde ao "scraper" previsto para a Sprint 1.

Etapa 6 – Construção do gerador de dados sintéticos

O gerador deve ser um pacote Python executável de ponta a ponta, com semente fixa e fator de escala (por exemplo, 10% da população ou um único distrito para testes). A sequência recomendada é:

1. **Estrutura territorial:** carregar DS, USF e equipes reais; criar microáreas, domicílios e famílias conforme as contagens do SISAB e do Censo por setor.
2. **População base:** gerar residentes com sexo, idade e cor/raça ajustadas por IPF (*iterative proportional fitting*) às marginais do Censo, por setor ou bairro.
3. **Cobertura:** sortear quem está cadastrado e vinculado a cada equipe, de modo que o total por equipe bata com o SISAB e o total geral fique em torno de 80% dos residentes.
4. **Atributos dependentes:** sortear escolaridade, renda, deficiência, orientação sexual e identidade de gênero de acordo com um DAG documentado (ex.: idade → deficiência; idade → orientação declarada).
5. **Comportamento de registro em duas etapas:** primeiro, se a equipe pergunta e registra (efeito de equipe dominante, com componente de unidade e componente próprio da equipe); depois, se a pessoa aceita informar. As respostas também são geradas para crianças, como acontece no PEC. A calibração usa as proporções Sim/Não/Não informado de cada USF da planilha.
6. **Dinâmica no tempo:** gerar competências mensais (por exemplo, de janeiro de 2023 a setembro de 2026), com novos cadastros, atualizações de versão, mudanças de território, óbitos, tendência própria de cada equipe e ações formativas sorteadas em datas e equipes conhecidas, com efeito definido na Tabela 6.
7. **Atendimentos:** gerar a frequência de consultas por idade e sexo e os problemas registrados (CIAP2/CID-10) a partir da produção pública do SISAB, com data do atendimento e data de digitação.
8. **Identificadores e textos:** usar Faker (pt_BR) para nomes e endereços e gerar CPF/CNS sintéticos com dígito verificador válido, mas sem correspondência com pessoas reais.

Dois métodos sustentam o gerador. O primeiro é o ajuste proporcional iterativo (IPF), de Deming e Stephan (1940): parte-se de uma tabela de contingência inicial (por exemplo, idade ×

cor/raça de um setor) e ajustam-se, alternadamente, linhas e colunas até que os totais coincidam com as marginais do Censo. O segundo é o modelo de registro em duas etapas, que sorteia para cada pessoa:

1. **se foi perguntada e teve a resposta registrada**, com probabilidade que depende do efeito da equipe (um componente comum à unidade e outro próprio da equipe), de ação formativa recente e da tendência no tempo; quem não é perguntado fica como "não informado";
2. **se aceitou informar**, com probabilidade que depende da equipe, da idade (a aceitação cai com a idade, como na PNS) e de ação formativa recente; o resultado é "Sim" ou "Não".

Os coeficientes desse modelo são definidos na calibração. Os efeitos de equipe são sorteados de distribuições cuja média reproduz a proporção de cada USF na planilha e cuja variância dentro da USF é a premissa testada na análise de sensibilidade. Se a Secretaria confirmar que o "Não" também é marcado quando a pergunta não é feita (Apêndice A), parte dos não perguntados passa a sair como "Não" em vez de "não informado"; o parâmetro fica no CSV de premissas.

Etapa 7 – Injeção de problemas de qualidade

Para que o banco reproduza o desafio real, introduzir de forma controlada e registrada:

- "Não informado" e "Não" que dependem da equipe e de outras variáveis (ausência não aleatória, MNAR): equipes que perguntam e equipes que não perguntam, como no caso relatado de uma equipe em que quase ninguém do território havia sido perguntado.
- Raça/cor registrada em categoria errada, concentrada em algumas equipes: excesso de "amarela" incompatível com o território e predominância de "branca" em territórios de maioria preta e parda. Campo vazio só em pequena proporção de cadastros legados.
- Raça/cor divergente entre versões do cadastro do mesmo cidadão.
- Duplicidades: a mesma pessoa com dois registros de cidadão (um com CPF, outro só com CNS, nome com variação de grafia); cadastros desatualizados (pessoas que mudaram sem registro de saída).
- Respostas de orientação sexual e identidade de gênero registradas para crianças de 0 a 10 anos.
- Erros de digitação em nomes e endereços, datas inválidas, inconsistências entre idade e escolaridade e atraso entre atendimento e digitação.

Cada defeito injetado deve ser marcado na tabela de controle (gabarito), o que permite medir se as rotinas de qualidade e os modelos de detecção os encontram.

Etapa 8 – Carga e validação

1. Carregar os CSV gerados na camada *staging* e transformar para o núcleo com procedimentos SQL.
2. Testar integridade: chaves, restrições CHECK, cardinalidades esperadas.
3. Validar a calibração: comparar as marginais do banco com as do Censo (pirâmide, cor/raça, deficiência), com os cadastros do SISAB e com as metas por USF; aceitar diferenças dentro de uma tolerância definida (ex.: ±1 ponto percentual).
4. Reproduzir, com visões SQL, as colunas da planilha da Secretaria (Tabela 1) a partir do banco sintético, por USF e também por equipe. Esse é o teste de aceitação mais convincente para a stakeholder.

A visão de monitoramento precisa de dois cuidados: contar só a **versão vigente** do cadastro de cada cidadão na data de corte (cada cidadão tem várias versões, e contá-las todas inflaria os totais) e calcular a idade na data de corte, e não na data em que a consulta roda. A Tabela 9 mostra como cada coluna da planilha é obtida a partir do banco.

Tabela 9 – Reprodução das colunas da planilha a partir do banco

Coluna da planilha	Regra de cálculo no banco
Distrito, USF, endereço	Junção equipe → unidade → distrito sanitário; endereço e município vêm das tabelas de território, sem digitação
Dia/Mês	Data de corte da tabela de parâmetros, única para toda a carga
Cidadãos Ativos (H)	Cidadãos cuja versão mais recente do cadastro, até a data de corte, não tem saída registrada
Criança cadastrada (I)	Entre os ativos, os que têm idade na data de corte menor que a idade mínima elegível (parâmetro = 11)
Cidadãos Ativos / Dado real (J)	H − I
Sim, Não, Não informado – dado real (M, Q, …)	Contagem de “Deseja informar” = Sim, = Não e sem registro, excluídas as crianças
Percentuais (N, R, …)	Cada contagem dividida por J, calculada na consulta e nunca armazenada
Recorte por equipe	Mesma regra, agrupando por INE em vez de CNES: é a granularidade pedida pela Secretaria

Fonte: elaborado pelo grupo.

Etapa 9 – Camada analítica e painel

Construir visões e tabelas-fato em formato longo (competência, DS, CNES, INE, marcador, categoria, faixa etária, contagem) e conectá-las ao Power BI ou ferramenta equivalente, como pede o briefing. Indicadores mínimos: proporção de aceitação em informar orientação sexual e identidade de gênero por equipe, com ranqueamento dentro de cada unidade; distância entre a distribuição de raça/cor registrada pela equipe e a distribuição censitária do território; pes-

soas com deficiência por tipo e território; distribuição racial por DS; e a série histórica de cada indicador, com as ações formativas marcadas no tempo. O mapa por Distrito Sanitário, pedido pela Secretaria em 01/09, usa as malhas territoriais da Prefeitura e nunca o endereço do cidadão.

Etapa 10 – Aplicações: SGBD, inferência estatística e aprendizado de máquina

SGBD. O próprio banco cobre os modelos conceitual, lógico e físico, além de visões, índices, procedimentos e análise de desempenho com volume realista.

Inferência estatística. Como os parâmetros verdadeiros são conhecidos, é possível: construir intervalos de confiança (por exemplo, de Wilson) para a proporção de aceitação de cada equipe e mostrar por que equipes pequenas precisam de estimadores com encolhimento (beta-binomial ou Bayes empírico) antes de entrar num ranqueamento; comparar proporções entre territórios; testar a divergência entre a distribuição de raça/cor registrada e a censitária (qui-quadrado ou distância de Hellinger); e medir o viés da estimativa ingênua de prevalência quando a ausência não é aleatória.

Aprendizado de máquina (problema supervisionado de Machine Learning I). O problema principal é de **regressão**, na formulação apresentada no kick-off:

Tabela 10 – Ficha do problema supervisionado

Elemento	Definição
Unidade de observação	Equipe (INE) × período. O período é parâmetro: o gerador produz competências mensais, e a Secretaria indicou atualização quadrimestral ou semestral. Com quadrimestres de 2023 a 2026 e 384 equipes, são cerca de 4,2 mil observações por quesito.
Alvo	Proporção de aceitação em informar a orientação sexual (e, em segundo modelo, a identidade de gênero) da equipe no período seguinte, calculada sobre o “dado real”. Variável contínua entre 0 e 1, observável em todos os períodos encerrados.
Entradas (medidas até o fim do período de referência)	Defasagens do próprio indicador; proporção de não informados; tamanho do cadastro e composição por idade e sexo; Distrito Sanitário e tipo de equipe; distância da raça/cor registrada em relação ao Censo; atraso médio de digitação; ações formativas realizadas ou programadas.
Partição	Temporal: treino nos períodos iniciais e teste no último; validação cruzada em janela deslizante (*walk-forward*), sem vazamento de informação futura.
Linhas de base	Persistência (repete o período anterior) e média móvel dos três períodos anteriores. O modelo só se justifica se superá-las.
Algoritmos	KNN, regressão linear e regularizada, árvore de decisão, floresta aleatória e reforço de gradiente.
Métricas	MAE, RMSE e R^2, estratificados por Distrito Sanitário; para a decisão de priorização, precisão nas k primeiras equipes (*precision@k*), com k igual à capacidade de oficinas de cada distrito.
Uso no produto	Fila de equipes prioritárias; o resíduo (observado − previsto) depois de uma oficina serve de termo de comparação para avaliar a ação.

Fonte: elaborado pelo grupo a partir da revisão do kick-off (12/09/2026) e do registro da reunião de 01/09/2026.

O dado sintético dá ao grupo uma vantagem que o dado real não daria: como o efeito verdadeiro das oficinas é conhecido, dá para verificar se a comparação entre o observado e o previsto recupera esse efeito. Como tarefa complementar, de classificação em nível de registro, pode-se treinar um modelo para sinalizar registros com defeito injetado (duplicidade provável, raça/cor inconsistente com o território), usando o gabarito da Etapa 7 como rótulo. O alvo alternativo de utilização da APS (contatos por cem cadastrados no período seguinte), estudado pelo grupo em agosto, também é calculável a partir das tabelas de atendimento.

> **Salvaguarda**
>
> Nenhum modelo infere ou imputa o valor de raça/cor, orientação sexual, identidade de gênero ou deficiência de um cidadão. São informações autodeclaradas, e as duas últimas dependem de consentimento no próprio fluxo de coleta. O sistema pode sinalizar registros e territórios que merecem revisão, nunca dizer qual seria o conteúdo do campo. Por isso, a imputação de valores ausentes desses campos não faz parte do projeto.

Etapa 11 – Documentação, reprodutibilidade e experimentos

1. Manter código, parâmetros e DDL em um repositório Git, com README e instruções de execução.
2. Publicar um *data card*: finalidade, fontes, premissas, defeitos injetados e limitações.
3. Registrar a versão de cada fonte e a data de acesso; reexecutar o gerador ao atualizar parâmetros.
4. Registrar os experimentos de aprendizado de máquina no MLflow, com artefatos em MinIO e ambiente em Docker, como exige Machine Learning I; cada execução guarda a semente e a versão do banco sintético usado.

7 CRONOGRAMA

O cronograma segue o calendário da disciplina. Em 16 de outubro de 2026, o SR1 (03/10) já passou e restam cinco entregas até o SR2, em 5 de dezembro, que é também a avaliação final de Machine Learning I. A Tabela 11 distribui as etapas por essas entregas.

Tabela 11 – Cronograma por entrega da disciplina

Entrega	Etapas	Entregável
17/10 – Sprint 1	0, 1 e 2; início da 5	Escopo e ficha do problema supervisionado; dicionário de dados; ER revisado; coleta automática do SIDRA (“scraper”); histórias priorizadas
24/10 – Sprint 2	3, 4 e 5; início da 6	DDL e domínios no repositório; CSV de parâmetros versionados; gerador com estrutura territorial e população base (um distrito)
07/11 – Sprint 3	6, 7 e 8; início da 9 e da 10	Gerador completo com série mensal e gabarito de defeitos; relatório de calibração; visões que reproduzem a planilha; dashboard funcional; linhas de base e primeiros modelos (KNN, regressão, árvore)
14/11 – Sprint 4	9 e 10	Validação cruzada temporal e comparação de algoritmos no MLflow; ranqueamento por equipe e mapa por DS no painel
21/11 – Validação	8 e 9	Apresentação à Secretaria da planilha reproduzida e do painel por equipe; ajustes a partir do retorno
28/11 – Preparação SR2	11	Escolha justificada do modelo final; *data card*; README; material da apresentação
05/12 – SR2	—	MVP final apresentado (também projeto final de Machine Learning I)

Fonte: elaborado pelo grupo a partir do documento de requisitos técnicos e de projetos 2026.2.

O caminho crítico é o gerador com série temporal (Sprint 3): sem ele não há alvo para os modelos nem dado para o painel. Se o prazo apertar, a prioridade é gerar um único distrito com todas as competências antes de escalar para o município.

8 RISCOS, LIMITAÇÕES E CONSIDERAÇÕES ÉTICAS

Tabela 12 – Riscos e mitigação

Risco	Efeito	Mitigação
Falta de dado oficial sobre identidade de gênero	Parâmetro incerto	Usar Spizzirri et al. (2021) com intervalo e análise de sensibilidade
Categorias de deficiência incompatíveis	Distorção por tipo	Tabela de correspondência documentada (Tabela 7)
Amostra pequena da PNS para o Recife	Estimativa instável	Usar PE ou Nordeste como valor central, com intervalo
Semântica incerta do “Não” em “Deseja informar?”	Indicador de aceitação mal interpretado	Pergunta à Secretaria (Apêndice A); parâmetro no gerador para os dois cenários
Circularidade em ML	Conclusões falsas sobre a população	Declarar limites; focar em qualidade de dados e métodos; testar se o método recupera efeitos conhecidos
Inferência de atributo autodeclarado	Violação da autodeclaração e da LGPD	Proibida no desenho (Etapa 10); modelos operam sobre equipe × período ou sinalizam registros para revisão
Forma de acesso aos dados reais indefinida	Camada *staging* incompatível com o dado real	Perguntas do Apêndice A ao núcleo de informação; *staging* isolada do núcleo
Volume de dados elevado	Lentidão nos testes	Fator de escala; índices; geração por distrito
Reforço de estereótipos nas associações programadas	Viés contra grupos vulnerabilizados	Basear cada associação em literatura citada; revisão pelo grupo e pela stakeholder
Uso indevido da planilha da SESAU	Exposição de documento interno	Autorização formal; usar só agregados

Fonte: elaborado pelo grupo.

Do ponto de vista ético, o uso de dados sintéticos é a resposta adequada à LGPD enquanto o acesso não é pactuado, mas não dispensa cuidado: os grupos atendidos pelas políticas de equidade são historicamente vulnerabilizados, e as relações programadas no gerador podem reproduzir preconceitos se não forem fundamentadas. Toda associação entre marcadores sociais deve vir de fonte citada. Os resultados devem ser apresentados sempre como demonstração de método. Quando o produto for apontado para os dados reais, valem as condições já discutidas com a Secretaria: unidade de análise agregada (equipe e período), nenhuma geolocalização de cidadão (a própria Secretaria declarou não ter interesse no endereço individual) e instrumento jurídico para o tratamento de dados pessoais sensíveis, na acepção do artigo 11 da LGPD. A Resolução CIT n.º 26/2017, que trata do Plano Operativo da Política Nacional de Saúde Integral LGBT, reforça a necessidade de qualificar a informação sobre orientação sexual e identidade de gênero nos sistemas do SUS, o que dá relevância ao produto proposto.

9 CONCLUSÃO

A planilha usada hoje pela gestão é um relatório agregado, montado manualmente, unidade por unidade, a partir do Relatório Consolidado de Cadastro Individual do PEC. Ela não permite cruzar marcadores, não chega ao nível de equipe e não forma série histórica, e o próprio processo deixou de ser executado de forma contínua. A proposta do grupo, de emular os dados em um banco estruturado e calibrado em fontes oficiais, é viável e atende ao briefing, aos requisitos declarados pela Secretaria em 1.º de setembro e às disciplinas envolvidas.

A viabilidade depende de seis condições: modelar o banco pelo LEDI APS e pelas fichas do e-SUS; usar os dados públicos reais de estrutura e cobertura (CNES, SISAB e os agregados da planilha); gerar a população com código reprodutível calibrado no IBGE, e não com linhas escritas por IA; simular os problemas de qualidade de registro tal como acontecem no fluxo real; gerar a dinâmica no tempo, com equipes, períodos e ações formativas; e declarar as limitações dos dados sintéticos. Cumpridas essas condições, o grupo entrega à Secretaria um produto que pode ser reaproveitado com os dados reais, dentro da sua própria rede e em conformidade com a LGPD, e entrega a Machine Learning I um problema supervisionado completo, com alvo, linhas de base e métricas ligadas a uma decisão real de gestão.

REFERÊNCIAS

BRASIL. Lei n.º 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 15 out. 2026.

BRASIL. Ministério da Saúde. Portaria GM/MS n.º 344, de 1.º de fevereiro de 2017. Dispõe sobre o preenchimento do quesito raça/cor nos formulários dos sistemas de informação em saúde. Brasília: MS, 2017.

BRASIL. Ministério da Saúde. *Ficha de Cadastro Individual (CI/e-SUS AB v5.2)*. Brasília: MS. Disponível em: https://sisaps.saude.gov.br/esus/upload/docs/ficha_cadastro_individual.pdf. Acesso em: 15 out. 2026.

BRASIL. Ministério da Saúde. *Ficha de Atendimento Individual*. Brasília: MS. Disponível em: https://sisaps.saude.gov.br/esus/upload/docs/ficha_atendimento_individual.pdf. Acesso em: 15 out. 2026.

BRASIL. Ministério da Saúde. *Manual do PEC e-SUS APS*: relatórios. Disponível em: https://sisaps.saude.gov.br/sistemas/esusaps/docs/manual/PEC/PEC_08_relatorios/. Acesso em: 15 out. 2026.

BRASIL. Ministério da Saúde. *Layout e-SUS APS de Dados e Interface (LEDI APS)*, versão 8.7.0. Disponível em: https://integracao.esusaps.bridge.ufsc.tech/ledi/index.html. Acesso em: 15 out. 2026.

BRASIL. Ministério da Saúde. *e-SUS APS: documentação do Data Warehouse do PEC*. Disponível em: https://integracao.esusab.ufsc.br/dw. Acesso em: 15 out. 2026.

BRASIL. Ministério da Saúde. Comissão Intergestores Tripartite. Resolução n.º 26, de 28 de setembro de 2017. Plano Operativo da Política Nacional de Saúde Integral LGBT. Disponível em: https://saude.campinas.sp.gov.br/saude/lista_legislacoes/legis_2017/U_RS-MS-CIT-26_280917.pdf. Acesso em: 15 out. 2026.

CANAVESE, D. *et al.* Pela urgente e definitiva inclusão dos campos de identidade de gênero e orientação sexual nos sistemas de informação em saúde do SUS: o que podemos aprender com o surto de monkeypox? *Ciência & Saúde Coletiva*, v. 27, n. 11, p. 4191-4194, 2022. DOI: 10.1590/1413-812320222711.12902022. Disponível em: https://scielosp.org/pdf/csc/2022.v27n11/4191-4194/pt. Acesso em: 15 out. 2026.

CESAR SCHOOL. *DADOS: requisitos técnicos e de projetos 2026.2*. Recife, 2026. Documento interno da disciplina.

COSEMS-SC. *Nota técnica: relatório de cadastros*. Florianópolis, 2023. Disponível em: https://www.cosemssc.org.br/wp-content/uploads/2023/02/nota_tecnica_relatorio_cadastro-1.pdf. Acesso em: 15 out. 2026.

DEMING, W. E.; STEPHAN, F. F. On a least squares adjustment of a sampled frequency table when the expected marginal totals are known. *The Annals of Mathematical Statistics*, v. 11, n. 4, p. 427-444, 1940.

EQUIPE 2 – NEXUS DATA. *Registro técnico de reunião com o parceiro institucional*: levantamento de requisitos, arquitetura da informação da Atenção Primária e condições de acesso aos dados do PEC/e-SUS APS. Recife: CESAR School, 2026. Documento interno.

IBGE. *Censo Demográfico 2022*: tabelas 9514, 9605, 10125 e 10127. Sistema IBGE de Recuperação Automática (SIDRA). Disponível em: https://sidra.ibge.gov.br. Acesso em: 15 out. 2026.

IBGE. *Orientação sexual autoidentificada da população adulta*: Pesquisa Nacional de Saúde 2019. Rio de Janeiro: IBGE, 2022. Disponível em: https://agenciadenoticias.ibge.gov.br/media/com_mediaibge/arquivos/dc3c7903468565be702f076f9795980a.pdf. Acesso em: 15 out. 2026.

IBGE. *Pesquisa Nacional por Amostra de Domicílios Contínua*. Disponível em: https://www.ibge.gov.br/estatisticas/sociais/trabalho/17270-pnad-continua.html. Acesso em: 15 out. 2026.

IBGE. Agência de Notícias. *Em pesquisa inédita do IBGE, 2,9 milhões de adultos se declararam homossexuais ou bissexuais em 2019*. Disponível em: https://agenciadenoticias.ibge.gov.br/agencia-noticias/2012-agencia-de-noticias/noticias/33785-em-pesquisa-inedita-do-ibge-2-9-milhoes-de-adultos-se-declararam-homossexuais-ou-bissexuais-em-2019. Acesso em: 15 out. 2026.

RECIFE. Secretaria de Saúde. Secretaria Executiva de Atenção Básica. *Projeto 3 – Dados*: apresentação do desafio (Dados PEC e-SUS). Recife, 2026. Documento interno.

SPIZZIRRI, G. *et al.* Proportion of people identified as transgender and non-binary gender in Brazil. *Scientific Reports*, v. 11, n. 1, 2021. DOI: 10.1038/s41598-021-81411-4. Disponível em: https://repositorio.unesp.br/handle/11449/207170. Acesso em: 15 out. 2026.

APÊNDICE A – PERGUNTAS PARA A STAKEHOLDER

A Tabela 13 reúne as perguntas formuladas pelo grupo e a situação de cada uma após a reunião de 01/09. Só as perguntas em aberto precisam ser levadas à Secretaria e ao núcleo de informação, inovação e monitoramento.

Tabela 13 – Situação das perguntas à Secretaria

N.º	Pergunta	Situação
1	Qual a faixa etária considerada “criança” e por que ela é retirada do denominador?	**Respondida:** 0 a 10 anos, por orientação de não perguntar OS/IG nessa idade (decisão de gestão). **Falta confirmar** se os 10 anos completos estão excluídos.
2	O que é a data “30/06” e a que período ela se refere?	**Parcial:** é a data de extração de cada linha e varia entre unidades. **Falta saber** por que o arquivo “JUL–SET” traz 30/06 e qual data de corte adotar.
3	Quais são as colunas depois de U (identidade de gênero, nome social, outros marcadores)?	**Em aberto.**
4	Há interesse no recorte por equipe (INE) e por microárea?	**Respondida:** equipe é a demanda principal; microárea não foi pedida.
5	O grupo pode usar os totais agregados da planilha como metas de calibração?	**Em aberto** (pedir autorização formal).
6	Quais indicadores das políticas de deficiência e da população negra são prioritários?	**Parcial:** casos de uso relatados (atendimento em Libras por território; anomalias de raça/cor). Falta a lista formal.
7	A Secretaria tem acesso ao banco PostgreSQL do PEC, ao *Data Warehouse* ou apenas à exportação CSV?	**Em aberto**; depende do núcleo de informação.
8	Qual a versão do PEC usada no município (para alinhar com o LEDI)?	**Em aberto.**
9	A instalação do PEC do Recife é do tipo Prontuário ou Centralizadora?	**Em aberto.** Define se haverá dado em nível de registro.
10	Na prática, o “Não” em “Deseja informar?” registra só a recusa do usuário ou também casos em que a pergunta não foi feita?	**Em aberto.** Muda a leitura do indicador e um parâmetro do gerador.
11	Com que periodicidade os indicadores precisam ser atualizados?	**Respondida:** quadrimestral ou semestral, desde que rápida e simples.
12	A visualização territorial é necessária?	**Respondida:** sim, mapa por Distrito Sanitário, sem endereço de cidadão.
13	Quais equipes receberam oficinas ou materiais formativos, e quando?	**Em aberto.** Mesmo agregada, essa informação calibra o efeito das ações no gerador.

Fonte: elaborado pelo grupo a partir do registro da reunião de 01/09/2026.

APÊNDICE B – LISTA DE VERIFICAÇÃO DA VALIDAÇÃO

Tabela 14 – Lista de verificação da validação do banco sintético

Item	Critério de aceite
Pirâmide etária	Diferença por faixa de 5 anos ≤ 1 ponto percentual em relação ao Censo 2022, na população residente gerada
Cor ou raça	Diferença ≤ 1 p.p. por categoria, no município e por DS (antes da injeção de defeitos)
Cobertura	Cadastrados por equipe compatíveis com o SISAB; total em torno de 80% dos residentes
Deficiência	Prevalência total entre 8% e 9% (2+ anos); distribuição por tipo coerente com a Tabela 7
Orientação sexual / identidade de gênero	Dentro dos intervalos da Tabela 6
“Deseja informar?” por USF	Correlação alta com as proporções Sim/Não/Não informado da planilha da SESAU
Dispersão entre equipes	Variância entre equipes da mesma USF maior que zero e igual à premissa usada
Série temporal	Todas as competências presentes para todas as equipes; efeito das oficinas igual ao parametrizado (verificado por diferença antes/depois em dado sem ruído)
Regra do “dado real”	Idade calculada na data de corte; idade mínima lida da tabela de parâmetros
Integridade referencial	Nenhuma violação de FK, CHECK ou UNIQUE
Defeitos injetados	Quantidade igual à registrada no gabarito
Reprodutibilidade	Mesma semente gera banco idêntico (hash dos CSV)
Reprodução da planilha	A visão de monitoramento reproduz as colunas da planilha (Tabela 9), por USF e por equipe, sem contar mais de uma versão de cadastro por cidadão

Fonte: elaborado pelo grupo.