PROJETO 3 – DADOS · CESAR SCHOOL · 2026.2
Desafio: Secretaria Executiva de Atenção Básica – Secretaria de Saúde do Recife

Plano metodológico da Etapa 6: gerador de dados sintéticos da Atenção Primária do Recife

fundamentos probabilísticos, critérios de pesquisa quantitativa e viabilidade

Equipe 2 – Nexus Data · Projeto 3 (Prof. Lucas Farias) · Machine Learning I (Prof. Diego Bezerra)

Recife, 22 de outubro de 2026 · Documento complementar ao plano *Emulação de dados da APS para as políticas de equidade do Recife* (v3)

1 INTRODUÇÃO

O plano de emulação do grupo prevê, na Etapa 6, um pacote Python que gere, com semente fixa e fator de escala, a população cadastrada na Atenção Primária do Recife e o seu histórico mensal. O plano organiza a etapa em oito passos (estrutura territorial, população base, cobertura, atributos dependentes, registro em duas etapas, dinâmica no tempo, atendimentos e identificadores) e indica dois métodos: o ajuste proporcional iterativo (IPF) e o modelo de registro em duas etapas.[1] O plano não diz, porém, qual modelo estatístico sustenta cada passo, como cada parâmetro será estimado, como saber se o resultado está certo, nem quais escolhas não podem ser decididas com os dados disponíveis. Este documento responde a essas quatro perguntas.

O texto tem três objetivos: (i) definir, para cada passo da Etapa 6, o método probabilístico ou inferencial adotado, os parâmetros e as fontes de cada um e o critério de verificação; (ii) incorporar as evidências reunidas na pesquisa bibliográfica sobre uso do SUS no Recife pelas populações LGBTQIAPN+, pessoas com deficiência e população negra, e nos cinco documentos acrescentados ao projeto em 22/10/2026; e (iii) avaliar a viabilidade do conjunto no prazo da disciplina. A Etapa 6 se limita a gerar a *verdade* do banco sintético e o comportamento de registro. A injeção de defeitos fica na Etapa 7, a carga e a validação no SGBD na Etapa 8, e o uso dos dados em inferência e aprendizado de máquina na Etapa 10.

Parecer

O plano da Etapa 6 é viável no prazo da Sprint 3 (07/11/2026) e tem base científica, desde que seis condições sejam cumpridas:

- tratar o gerador como um modelo probabilístico explícito, com um grafo acíclico dirigido (DAG) e efeitos aleatórios por nível hierárquico;
- calibrar apenas o que tem fonte oficial e registrar todo o resto como premissa, com intervalo de sensibilidade;
- adotar a estimativa indireta de cor ou raça por Distrito Sanitário obtida do boletim da SESAU (seção 3.2);
- revisar a premissa de dispersão entre equipes (seção 4.5);
- tratar a semântica do “Não” como cenário, porque os agregados não a identificam;
- validar por tolerância e equivalência, e não por testes de significância, gravando à parte a verdade latente que a Etapa 10 usará como gabarito.

1. EQUIPE 2 – NEXUS DATA. *Emulação de dados da Atenção Primária à Saúde para as políticas de equidade do Recife*, v3, Etapa 6, p. 25-26. Os parâmetros citados neste documento sem outra indicação vêm de `parametros_oficiais.md`, v1.0.0, de 20/10/2026 (Etapa 5).

2 ENQUADRAMENTO CIENTÍFICO

2.1 O gerador como modelo probabilístico

Do ponto de vista estatístico, o gerador é uma distribuição de probabilidade conjunta $P_{\theta}(\mathbf{X})$ sobre a população sintética. **X** reúne os atributos de pessoas, domicílios, equipes e competências, e θ, os parâmetros. Sortear cada variável de forma independente produziria combinações irreais, como o próprio plano adverte. Por isso a conjunta é fatorada segundo um DAG, em que cada variável depende só dos seus "pais" (Pearl, 2009):

$$P(\mathbf{X}) = \prod_j P(X_j \mid \mathrm{pa}(X_j); \theta_j).$$

A geração segue a ordem topológica do grafo: primeiro as variáveis sem pais, depois as que dependem delas, até a última (amostragem ancestral). A estrutura hierárquica da rede (DS ⊃ bairro; USF ⊃ equipe ⊃ microárea ⊃ domicílio ⊃ pessoa) entra como efeitos aleatórios em cada nível, como nos modelos multinível (Gelman; Hill, 2007), e o tempo entra como índice das competências mensais. Os parâmetros se dividem em três classes, que o código deve manter separadas: θ_{cal}, calibrados em dado oficial; θ_{lit}, tirados de literatura com intervalo; e θ_{prem}, premissas do grupo.

Há uma diferença de método em relação à maior parte da literatura de dados sintéticos. Na proposta original de Rubin (1993) e nos métodos atuais (Drechsler, 2011), o sintético é produzido a partir de um microdado real, cuja distribuição o modelo aprende. Aqui não existe microdado real, porque a LGPD impede o acesso. O método pertence, então, à família da *síntese de populações* ou microssimulação espacial, que monta indivíduos a partir de tabelas agregadas (Beckman; Baggerly; McKay, 1996; Williamson; Birkin; Rees, 1998; Lovelace; Dumont, 2016).[2] Isso tem uma consequência central: a fidelidade só pode ser verificada contra o que foi publicado. Toda relação conjunta que não consta de tabela oficial é premissa e precisa ser declarada.

2.2 O gerador como estudo de simulação

O banco sintético tem uma vantagem que o dado real não oferece: os parâmetros verdadeiros são conhecidos. Isso o torna um estudo de simulação no sentido da estatística metodológica. O protocolo de referência para esse tipo de estudo é o ADEMP (Morris; White; Crowther, 2019), que pede a definição prévia de objetivos, mecanismos geradores, estimandos, métodos e medidas de desempenho. A Tabela 1 aplica o protocolo ao projeto. Para isso, o gerador precisa gravar, além das tabelas do banco, um diretório `verdade/` com os efeitos latentes de cada equipe, as datas e os efeitos das oficinas e os atributos latentes de cada pessoa. Esse diretório nunca vai para a camada analítica.

2. Métodos generativos que aprendem com microdados, como redes adversariais (GAN, CTGAN) ou cópulas ajustadas a dados individuais, não se aplicam: exigiriam justamente o dado pessoal que o projeto não pode acessar.

Tabela 1 – Protocolo ADEMP aplicado ao gerador

Elemento	Definição no projeto
Objetivos (*Aims*)	(i) Verificar se o banco reproduz as metas oficiais e a planilha da SESAU; (ii) verificar se os métodos da Etapa 10 recuperam parâmetros conhecidos: efeito das oficinas, ranqueamento de equipes e prevalência sob ausência não aleatória.
Mecanismos geradores (*Data-generating mechanisms*)	Cenário base e cenários de sensibilidade (seção 5), definidos por dispersão entre equipes, semântica do "Não", mecanismo de ausência, efeito e alocação das oficinas e cobertura.
Estimandos (*Estimands*)	Proporção verdadeira de aceitação por equipe e período, $p_{e,t}$; efeito da oficina γ; variância entre equipes σ^2_v; prevalência adulta de LGB+; razão de utilização por grupo.
Métodos (*Methods*)	Os da Etapa 10: intervalo de Wilson, encolhimento beta-binomial ou Bayes empírico, diferenças em diferenças com adoção escalonada, regressões da Tabela 10 do plano.
Desempenho (*Performance*)	Viés, raiz do erro quadrático médio, cobertura dos intervalos de 95%, precision@k do ranqueamento, MAE do modelo supervisionado, cada um com seu erro-padrão de Monte Carlo.

Fonte: elaborado pelo grupo a partir de Morris, White e Crowther (2019).

2.3 Critérios de qualidade do banco sintético

Um banco sintético não é "verdadeiro" nem "falso": ele é adequado ou inadequado para um uso declarado. Os critérios da Tabela 2 traduzem, para este caso, os requisitos de validade, confiabilidade e transparência da pesquisa quantitativa. As medidas de utilidade de Snoke *et al.* (2018), que comparam o sintético com o microdado original, não se aplicam aqui por falta do original. Em seu lugar entram a fidelidade às tabelas publicadas e a capacidade de recuperar a verdade conhecida.

Tabela 2 – Critérios de qualidade e como medi-los

Critério	Pergunta	Medida
Fidelidade	As distribuições marginais e os cruzamentos publicados são reproduzidos?	Diferença em pontos percentuais, distância de variação total e de Hellinger, teste de equivalência (seção 6)
Coerência lógica	Os registros respeitam as regras do LEDI e do modelo lógico?	Zero violação das restrições R e das validações VC do modelo lógico antes da Etapa 7
Plausibilidade	Especialistas da SESAU reconhecem o comportamento das equipes?	Revisão da planilha reproduzida e do painel na validação de 21/11
Utilidade analítica	O banco sustenta o painel e o problema supervisionado e permite recuperar os parâmetros?	Desempenho do ADEMP (Tabela 1)
Reprodutibilidade	A mesma configuração gera o mesmo banco?	Hash SHA-256 idêntico dos arquivos para a mesma semente e versão
Transparência	Toda premissa está declarada e tem fonte?	Registro de premissas (Apêndice A), DAG com fonte por aresta (Apêndice B), *data card* (Gebru *et al.*, 2021)
Proteção e ética	Há risco de reidentificação ou de reforçar estereótipos?	Nenhum microdado real na entrada; associações entre marcadores sociais só com fonte; atributos latentes nunca expostos como se fossem dado

Fonte: elaborado pelo grupo.

3 EVIDÊNCIAS DISPONÍVEIS E SEU PAPEL NO GERADOR

3.1 Matriz de evidências

As fontes reunidas têm delineamentos muito diferentes: o Censo cobre toda a população, a PNS é uma amostra probabilística, o SINASC e o SIM são registros administrativos quase completos, os estudos de serviço descrevem quem chegou ao serviço e os estudos qualitativos ouvem amostras intencionais. Usá-las como se valessem o mesmo seria um erro de método. A Tabela 3 classifica cada fonte por delineamento e define o que ela pode fazer no gerador. Só as fontes de classe A cali-

bram valores. As de classe C indicam a direção de um efeito e o intervalo da análise de sensibilidade, mas não o valor central.

Tabela 3 – Classes de evidência e papel no gerador

Classe	Delineamento	Papel no gerador	Fontes
A	Censo ou registro administrativo de cobertura quase universal	Meta de calibração com tolerância estreita	Censo 2022 (SIDRA); CNES; boletim da SESAU de natalidade e mortalidade por raça/cor (SINASC e SIM); planilha da SESAU, quando autorizada
B	Amostra probabilística, ou estimativa derivada de fonte A com premissa explícita	Parâmetro estrutural com intervalo	PNS 2019; Spizzirri *et al.* (2021); estimativa indireta de raça por DS (seção 3.2); completude do quesito raça/cor (Oliveira *et al.*, 2025)
C	Estudo de serviço, de prontuário ou de amostra intencional	Direção do efeito e intervalo de sensibilidade; não fixa o valor central	Souza (2018); Santos e Melo (2022); Farias *et al.* (2023); Reichenberger *et al.* (2024)
D	Declaração de gestor, reportagem, relatório sem método descrito	Verificação de ordem de grandeza	Gonzaga (2022), no *Brasil de Fato*; relatório do Centro de Referência LGBT (2018)

Fonte: elaborado pelo grupo.

3.2 O que os novos documentos acrescentam

a) Boletim da SESAU n.º 01/2025: cor ou raça por Distrito Sanitário

Falta hoje ao gerador a distribuição de cor ou raça abaixo do município, porque os agregados por setor censitário ainda não foram coletados (pendência E6). O boletim de natalidade e mortalidade por raça/cor (RECIFE, 2025) traz, para cada DS, os nascidos vivos de 2024 por raça/cor da mãe, e também as taxas de natalidade de negras (12,8 por mil) e não-negras (7,5 por mil). Como as negras têm natalidade 1,71 vez maior, a participação nos nascimentos superestima a participação na população. A correção é direta. Se s_d é a proporção de nascidos de mães negras no DS d, entre negras e não-negras, e r = 12,8/7,5, a proporção de negros na população é estimada por

$$\hat{\pi_d} = s_d / [s_d + (1 - s_d)\, r].$$

O estimador passa num teste externo. Aplicado ao total do município (72,9% dos nascidos de mães negras), ele dá 61,1% de pretos e pardos entre pretos, pardos e brancos. O Censo 2022 dá 61,0%. A Tabela 4 mostra o resultado por DS. Duas premissas precisam ser declaradas: a razão de natalidade é a mesma em todos os distritos, e a composição de 2024 representa a de 2022. Com r variando ±15%, a estimativa do DS III vai de 29% a 36%, o que define o intervalo de sensibilidade. O mesmo boletim fornece os nascimentos e os óbitos de 2024 por raça e faixa etária. Eles alimentam a dinâmica demográfica (seção 4.6). Os números de consultas de pré-natal por raça calibram os atendimentos de pré-natal (seção 4.7).

Tabela 4 – Estimativa indireta da proporção de pretos e pardos por Distrito Sanitário

DS	Nascidos vivos de mães negras (%)	Pretos e pardos estimados (%)	Residentes por eSF/eAP	Teto de cobertura (%)
I	78,6	68,3	3.207	89
II	78,6	68,2	3.447	83
III	44,6	32,0	5.425	53
IV	71,3	59,3	4.476	64
V	78,6	68,3	3.466	83
VI	57,6	44,3	5.556	52
VII	81,5	72,1	2.517	100
VIII	82,7	73,7	2.107	100
Recife	72,9	61,1 (Censo: 61,0)	3.579	80

Fonte: elaborado pelo grupo com dados de RECIFE (2025, Tabela 3), do Censo 2022 e do CNES (Etapa 5). Percentuais calculados sobre negros e não-negros. Teto de cobertura = mín(1; 2.863 ÷ residentes por equipe), com 2.863 cadastrados por equipe no cenário de 80%.

A Tabela 4 mostra também uma regularidade com consequência para o passo de cobertura. Os distritos com menor proporção de negros (III e VI) são os que têm mais residentes por equipe e, portanto, a menor cobertura possível (correlação de Spearman de −0,90 entre as duas colunas, com só oito distritos). Assim, uma diferença de cobertura por raça aparece no banco pelo território, mesmo que o modelo de cadastro não dê peso algum à raça.

b) Completude do quesito raça/cor no Recife

Oliveira *et al.* (2025), de residentes da própria SESAU, mediram a completude do quesito raça/cor no SINASC, no SIM e no SIH do Recife entre 2006 e 2024. O SIM fica acima de 95% na maior parte do período. O SINASC oscila entre regular e excelente. O SIH sobe de 26–39% (2008–2012) até 100% em 2024. O artigo usa a escala de Romero e Cunha (2006): excelente acima de 95%, bom de 90% a 95%, regular de 70% a 89%, ruim de 50% a 69% e muito ruim abaixo de 50%. O gerador adota essa escala para classificar a completude que produz. O próprio artigo tem uma incoerência: classifica como “excelente” o valor de 83,46% (SIH, 2023), que pela escala é regular. Por isso o grupo deve aplicar a escala diretamente, sem copiar as classificações do texto. Os autores citam ainda um estudo em que só 2,2% dos registros de raça/cor tinham sido coletados por autodeclaração. É um sinal de que a heteroidentificação pela equipe é comum, o que justifica tratar o regime de classificação como atributo da equipe (seção 4.5).

c) Estudos com a população LGBTQIAPN+ no Recife

A tese de Souza (2018), do Instituto Aggeu Magalhães, ouviu em oficinas 29 mulheres lésbicas, bissexuais, trans e travestis usuárias do SUS no Recife (15 lésbicas e bissexuais, 14 trans e travestis), recrutadas de forma intencional por movimentos sociais, ONGs e dez UBS sorteadas. Só 46,7% das lésbicas e bissexuais e 42,9% das trans e travestis tinham vínculo com a UBS. No conjunto, são 13 de 29 (44,8%), com intervalo de Wilson de 95% entre 28% e 62%. Para comparação, a cobertura do município é de cerca de 80%. A tese relata ainda preconceito, constrangimento e afastamento do serviço. Por ser amostra intencional e pequena, o estudo é de classe C: indica que o vínculo e a disposição de informar podem ser menores nesse grupo, mas não fixa valor.

Santos e Melo (2022) descrevem o Espaço Trans do HC-UFPE a partir de 180 das 315 fichas de usuários. As demais não foram localizadas durante a implantação do prontuário eletrônico. Nas fichas analisadas, 66% eram mulheres trans, 70,6% pretos ou pardos (intervalo de Wilson de 63,5% a 76,7%), 65% tinham de 18 a 30 anos e havia 580 pessoas na fila. Nenhum usuário se declarou não binário, enquanto Spizzirri *et al.* (2021) estimam mais pessoas não binárias (1,19%) do que trans

(0,69%) na população. A diferença ilustra o viés de seleção dos estudos de serviço, que descrevem quem procura o processo transexualizador, e não a população. Somam-se a perda de 43% das fichas, que pode não ser aleatória, e a ausência de denominador populacional. Por isso o estudo não serve para calibrar identidade de gênero. Ele apenas sustenta, como direção, um gradiente etário.

A reportagem do *Brasil de Fato* (Gonzaga, 2022) registra a declaração do coordenador estadual de que o Ambulatório Patrícia Gomes tinha "mais de mil pessoas cadastradas" e que o estado tinha 11 ambulatórios LGBT, nove deles na região metropolitana. É evidência de classe D, útil só como verificação de ordem de grandeza. Com 1,17 milhão de adultos no Recife e 0,69% de pessoas trans, o gerador terá cerca de 8 mil adultos trans (entre 5,6 mil e 10,5 mil), um número compatível com um ambulatório de referência que atende mil pessoas LGBT.

d) A linha da planilha e a semântica do "Não"

O plano já registrava uma linha da planilha da SESAU com as respostas a "Deseja informar orientação sexual?". Entre os adultos, 37,8% responderam Sim, 58,4% Não e 3,8% ficaram sem informação. Entre as crianças, foram 10,0% Sim, 87,3% Não e 2,7% sem informação. Se as crianças de fato não fossem perguntadas e o "Não" registrasse só recusa, quase todas apareceriam como não informadas. Seja π a probabilidade de o campo ser marcado como "Não" quando a pergunta não é feita. Então P(NI) = $(1 - P_R)(1 - \pi)$ e P(Sim) = $P_R \cdot P_A$, em que P_R é a probabilidade de a pergunta ser feita e P_A a de a pessoa aceitar. A Tabela 5 mostra que leituras muito diferentes reproduzem exatamente a mesma linha.

Tabela 5 – Leituras compatíveis com a mesma linha da planilha, segundo π

π ("Não" sem pergunta)	**Adultos: perguntados (%)**	**Adultos: aceitam (%)**	**Crianças: perguntadas (%)**	**Crianças: aceitam (%)**
0 ("Não" é só recusa)	96,2	39,3	97,3	10,3
0,5	92,5	40,9	94,5	10,6
0,8	81,2	46,6	86,3	11,6
0,9	62,3	60,6	72,6	13,7
0,939 (máximo compatível com os adultos)	37,8	100,0	54,8	18,2

Fonte: elaborado pelo grupo a partir da linha 3 da planilha descrita no plano v3 (seção 2.2). Supõe π comum a adultos e crianças.

Duas conclusões saem daí. A primeira: a aceitação dos adultos não é identificável a partir dos agregados. Ela pode estar entre 39% e quase 100%, conforme π. A pergunta 10 do Apêndice A do plano precisa, portanto, ser respondida pela Secretaria antes que o indicador possa ser interpretado. Até lá, π entra no gerador como cenário. A segunda: para qualquer π comum a adultos e crianças, mais da metade das crianças daquela unidade teve o campo preenchido. O defeito "OS/IG registrada para criança" não é raro. Ele deve ser injetado na Etapa 7 com frequência alta, e não residual. A conclusão vale para uma unidade (1.132 crianças) e precisa ser conferida na planilha completa.

e) Pessoas com deficiência

Os estudos locais sobre pessoas com deficiência são qualitativos ou de análise de rede (Farias *et al.*, 2023; Reichenberger *et al.*, 2024). Descrevem barreiras de comunicação, de transporte e de regulação, além de espera longa na atenção especializada, mas não medem utilização. O dado quantitativo disponível é o do Censo 2022, já coletado: prevalência de 8,39% e gradientes por sexo, idade e cor ou raça. Para a utilização, a evidência é de classe C e aponta em duas direções: maior necessida-

de e mais barreiras. O efeito da deficiência sobre a utilização entra, por isso, como premissa com intervalo nos dois sentidos (seção 4.7).

4 MÉTODOS POR PASSO DA ETAPA 6

A Figura 1 resume o DAG do gerador. As arestas contínuas têm fonte de classe A ou B. As tracejadas são premissas com intervalo de sensibilidade. A lista completa, com a fonte de cada aresta, está no Apêndice B.

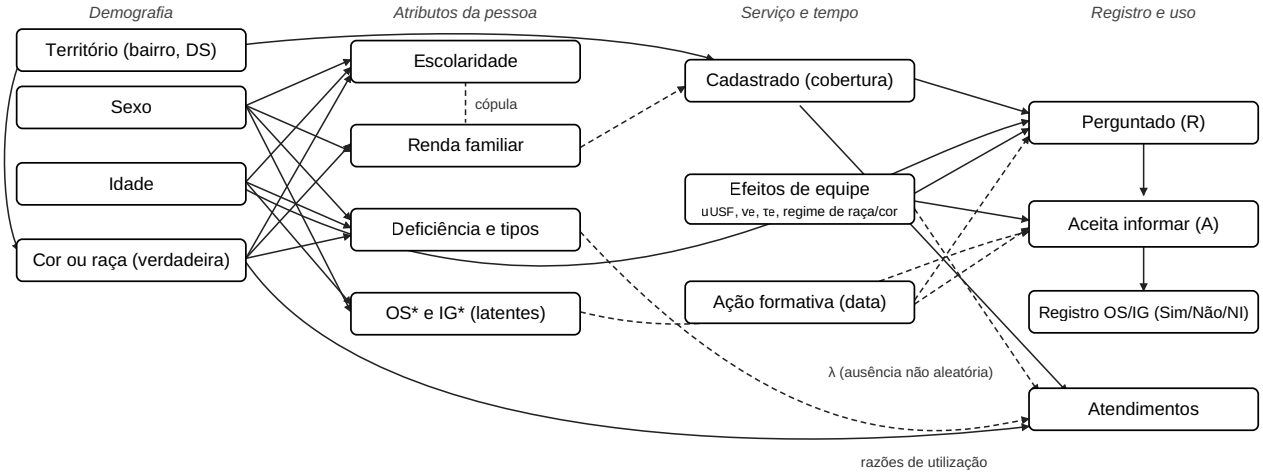


Figura 1 – Grafo acíclico dirigido do gerador (arestas principais)

Fonte: elaborado pelo grupo. Linha contínua: fonte de classe A ou B. Linha tracejada: premissa com intervalo. A cor ou raça depende do território pelo ajuste por DS (seção 4.2); a idade age sobre R pela regra das crianças. Não há aresta de cor ou raça para orientação sexual, porque a PNS 2019 não encontrou diferença.

4.1 Passo 1 – Estrutura territorial

Método. A estrutura é determinística onde há dado real e probabilística onde não há. Entram como estão: 8 DS, 94 bairros, 153 unidades e 432 equipes do CNES, com o histórico de ativação de 324 eSF + eAP em janeiro de 2023 a 416 em outubro de 2026. Cada equipe recebe como território o bairro da sua unidade. Quando um bairro tem várias equipes, a população é repartida na proporção da capacidade de cada uma. As microáreas de cada equipe são criadas em número $m_e = \lceil N_e/750 \rceil$, limitado a 12, que é o parâmetro histórico da PNAB de até 750 pessoas por ACS e até 12 ACS por equipe (BRASIL, 2011). Os domicílios de cada bairro seguem a contagem do Censo (547.461 no total). O tamanho do domicílio é sorteado de uma distribuição de Poisson truncada em zero, deslocada de modo que a média coincida com a do bairro (de 1,89 a 3,30 moradores). A distribuição empírica dos microdados da amostra do Censo substitui essa aproximação quando for processada.

Verificação. Totais de domicílios e moradores por bairro iguais aos do Censo, à escala adotada; nenhuma equipe sem microárea (VC12); número de equipes ativas por competência igual à série do CNES.

4.2 Passo 2 – População base

Método. A população é um tensor de contagens $X[b, s, a, r]$, com bairro, sexo, faixa etária e cor ou raça, ajustado por IPF (Deming; Stephan, 1940). A semente é a tabela 9606 do Censo (cor ou raça × sexo × idade no município), replicada por bairro. As restrições são três: (i) a população de cada bairro (tabela 9923); (ii) o cruzamento sexo × idade × raça do município (tabela 9606); e (iii) a cor ou raça por DS, obtida da Tabela 4. Antes do IPF principal, um IPF bidimensional DS × raça, semeado com a estimativa indireta, torna a restrição (iii) consistente com os totais de (i) e (ii). O IPF converge para a tabela de menor divergência de Kullback-Leibler em relação à semente que satisfaz

as restrições (Csiszár, 1975). Equivale à estimativa de máxima verossimilhança de um modelo log-linear cujas estatísticas suficientes são as marginais impostas (Bishop; Fienberg; Holland, 1975). Na prática, preserva as razões de chances da semente nas interações que não foram restringidas, como a relação entre raça e idade dentro do bairro.

```
# Listagem 1 – IPF sobre tensor numpy; alvos com keepdims=True
def ipf(semente, alvos, tol=1e-6, max_iter=500):
    x = semente.astype(float).copy()
    for it in range(1, max_iter + 1):
        desvio = 0.0
        for eixos, alvo in alvos:                  # ex.: ((0,), pop_bairro)
            outros = tuple(i for i in range(x.ndim) if i not in eixos)
            soma = x.sum(axis=outros, keepdims=True)
            desvio = max(desvio, float(np.abs(soma - alvo).max()))
            x *= np.divide(alvo, soma, out=np.zeros_like(soma), where=soma > 0)
        if desvio < tol:
            return x, it                           # registrar iterações no relatório
    raise RuntimeError("IPF não convergiu: marginais inconsistentes?")
```

A função foi testada numa tabela 2 × 2: convergiu em seis iterações e manteve a razão de chances da semente (0,667). Três cuidados acompanham o método. Células com zero na semente nunca recebem valor; zeros amostrais, como as 47 pessoas sem declaração de raça, recebem um ε pequeno, e zeros estruturais são mantidos. As marginais precisam somar o mesmo total, senão o algoritmo não converge. E o resultado é fracionário: a passagem para contagens inteiras usa o método truncar, replicar e sortear (TRS) de Lovelace e Ballas (2013), que preserva os totais em esperança e evita o viés do arredondamento simples. Por fim, cada pessoa recebe a idade simples sorteada dentro da faixa, segundo a tabela 9514, e a data de nascimento sorteada de modo uniforme dentro do ano.

Formação dos domicílios. Distribuir pessoas em domicílios sem regra produziria famílias com composição racial aleatória e impediria ligar a renda, que é domiciliar, às características dos moradores. No MVP, os domicílios são montados por regras: uma pessoa de referência adulta, um cônjuge com diferença de idade sorteada e os filhos com idades compatíveis. A homofilia racial fica registrada como premissa. Na melhoria, o método é a atualização proporcional iterativa (IPU) de Ye *et al.* (2009). Ela repondera domicílios-semente para ajustar ao mesmo tempo as marginais de domicílio e de pessoa. A semente seriam os microdados da amostra do Censo 2010 do Recife, que são públicos e trazem áreas de ponderação dentro do município, ou os de 2022, se já tiverem sido divulgados. É o desenho canônico da síntese de populações: estrutura do microdado antigo, marginais do censo novo.

Verificação. Pirâmide por faixa de cinco anos e cor ou raça no município e por DS dentro da tolerância da seção 6; número de iterações e desvio final do IPF no relatório; razões de chances da semente preservadas nas interações não restringidas.

4.3 Passo 3 – Cobertura

Método. O agente comunitário cadastra domicílios e famílias. Por isso a unidade de seleção é o domicílio, e não a pessoa (amostragem por conglomerados). Cada domicílio *h* do território da equipe *e* recebe a probabilidade

$$\text{logit}\, P(\text{cadastrado}_h) = \alpha_e + \beta_1 \cdot \text{renda}_h + \beta_2 \cdot \text{raça da pessoa de referência}_h .$$

O intercepto α_e é resolvido por bisseção para que o número esperado de pessoas cadastradas, $\Sigma_h\, p_h \cdot \text{tamanho}_h$, iguale a meta N_e da equipe (calibração do intercepto). O sorteio é de Poisson, que deixa o total variar de forma realista em torno da meta. Se for preciso acertar o total exato, usa-se a amostragem de Poisson condicional (Tillé, 2006). Dentro do domicílio cadastrado, cada morador fica de fora com uma pequena probabilidade (premissa de 1% a 3%). Enquanto a pendência E2 (cadas-

tros por equipe no SISAB) estiver aberta, a meta de cada equipe é a capacidade: em média 2.863 pessoas no cenário de 80%, limitada pela população do território, o que dá os tetos por DS da Tabela 4. A direção de β_1 (menor cadastro com maior renda) e de β_2 (maior dependência do SUS entre pessoas negras, apontada no boletim da SESAU) é sustentada pela evidência. Os valores são premissa, a substituir por razões de chances estimadas nos microdados da PNS 2019 (posse de plano de saúde e cadastro em USF), uma extensão da pendência E8. O cenário $\beta = 0$ é obrigatório, porque mostra quanto da desigualdade de cobertura vem só do território (seção 3.2a).

Verificação. Cadastrados por equipe dentro de ±3 erros-padrão da meta; total municipal entre 75% e 90% dos residentes; cobertura por DS igual ou abaixo do teto.

4.4 Passo 4 – Atributos dependentes

Cada atributo é sorteado da sua distribuição condicional aos pais no DAG. A Tabela 6 resume os modelos.

Tabela 6 – Modelos condicionais dos atributos

Atributo	Pais no DAG	Modelo	Fonte (classe)
Escolaridade	idade, sexo, cor ou raça	Categórica condicional; abaixo de 18 anos, regra de compatibilidade com a idade	Censo, tab. 10061 (A)
Renda familiar	raça e sexo da pessoa de referência; escolaridade	Categórica condicional; ligação com a escolaridade por cópula gaussiana (Nelsen, 2006) com ρ de premissa	Censo, tab. 10296 (A); ρ: premissa até a PNAD (E7)
Deficiência (sim/não)	idade, sexo, cor ou raça	Logística aditiva, ajustada por IPF às marginais sexo × idade e raça (modelo log-linear sem interação tripla)	Censo, tab. 10125 e 10132 (A)
Tipos de deficiência	deficiência	Bernoulli multivariada por cópula gaussiana com correlação permutável calibrada para reproduzir a união (Emrich; Piedmonte, 1991)	Censo, tab. 10127 e Tabela 7 do plano (A/B)
TEA	idade, sexo	Bernoulli condicional, independente das dificuldades funcionais	Censo, tab. 10145 (A)
OS* (latente)	idade, sexo	Categórica: LGB+ em 1,0% dos adultos, redistribuído por idade segundo o gradiente nacional (4,8%, 1,9%, 1,0% e 0,2% de 18–29 a 60+ anos); dentro de LGB+, 60% homossexual, 35% bissexual, 5% outra	PNS 2019 (B)
IG* (latente)	idade (premissa)	Categórica: trans 0,69%, não binário 1,19%, cisgênero o restante; gradiente etário e parcela de travestis como premissas	Spizzirri *et al.*, 2021 (B); direção: Santos e Melo, 2022 (C)

Fonte: elaborado pelo grupo. OS* e IG* são atributos verdadeiros e latentes: ficam só em `verdade/`; o banco recebe apenas o que for registrado no passo 5.

O ajuste dos tipos de deficiência mostra como o método funciona. As prevalências por tipo (visual 4,89%, auditiva 1,41%, física 3,95% e intelectual 1,62%) somam 11,9%. Sob independência, a união seria 11,4%, mas o Censo mede 8,39%: os tipos se sobrepõem. A cópula gaussiana resolve isso com um único parâmetro. Sorteia-se um vetor normal latente com correlação ρ entre os tipos, e cada tipo ocorre quando a sua coordenada passa do limiar da prevalência. Resolvendo por busca de raiz o valor de ρ que reproduz a união, obtém-se $\rho = 0{,}65$. Com os limites da deficiência física, ρ fica entre 0,57 e 0,72. A prevalência total e a de cada tipo saem certas por construção. A sobreposição deixa de ser um palpite.

A ausência de aresta entre cor ou raça e orientação sexual é uma decisão com fonte: a PNS 2019 não encontrou diferença significativa entre brancos (1,8%) e pretos e pardos (1,9%). Para iden-

tidade de gênero não há dado populacional por raça. O cenário central é de independência. O excesso de pretos e pardos no Espaço Trans (70,6%, contra 61% na população) pode vir da seleção de quem depende do SUS e não justifica, sozinho, uma aresta.

4.5 Passo 5 – Registro em duas etapas

Modelo. O comportamento de registro é um modelo logístico de efeitos mistos com dois estágios. Para a pessoa *i* da equipe *e*, numa versão do cadastro feita na competência *t*:

$$\text{logit}\, P(R_{it} = 1) = a^{\mathrm{R}}_{\mathrm{USF}} + v^{\mathrm{R}}_{e} + \tau_e t + \gamma_{\mathrm{R}} \cdot O_e(t) + \kappa \cdot \text{criança}_i$$

$$\text{logit}\, P(A_{it} = 1 \mid R = 1) = a^{\mathrm{A}}_{\mathrm{USF}} + v^{\mathrm{A}}_{e} + w_i + f(\text{idade}_i) + \lambda \cdot \text{LGB+}_i + \gamma_{\mathrm{A}} \cdot O_e(t)$$

Os efeitos de equipe $(v^{\mathrm{R}}_{e}, v^{\mathrm{A}}_{e})$ são normais bivariados com variância σ^2_{v} e correlação ρ_{RA}. O efeito de pessoa $w_i \sim \mathrm{N}(0, \sigma^2_{\mathrm{w}})$ persiste entre as versões do cadastro, de modo que respostas repetidas da mesma pessoa são correlacionadas. $O_e(t)$ indica oficina já realizada pela equipe. O registro observado é: Sim, se $R \wedge A$; Não, se $R \wedge \neg A$ ou, com probabilidade π, se $\neg R$; e não informado nos demais casos. A identidade de gênero segue a mesma estrutura, com parâmetros próprios e efeito de equipe correlacionado ao da orientação sexual.

Calibração por unidade. Com a planilha autorizada, os dois interceptos de cada USF são resolvidos de modo que as proporções esperadas de Sim e de não informado coincidam com as da unidade. Como os efeitos de equipe entram dentro da função logística, a proporção da USF é uma média sobre a distribuição de v_e, calculada por quadratura de Gauss–Hermite. Usar diretamente o logito da proporção observada como intercepto ignora a atenuação do modelo logístico-normal. O fator de correção é aproximadamente $(1 + 0{,}346\sigma^2)^{1/2}$ (Zeger; Liang; Albert, 1988). Com $\sigma = 1$, uma unidade com 30% de Sim exige mediana condicional de 26,5% entre as suas equipes, com 95% delas entre 5% e 72%. Sem a planilha, os interceptos das USF vêm de uma distribuição Beta ajustada à faixa observada de 3% a 53%. Tratando os extremos como estatísticas de ordem de 144 unidades, a distribuição é Beta(2,9; 10,7), com média de 21% e mediana de 20%. O ponto médio de 28% previsto na Etapa 5 superestima o centro de uma distribuição assimétrica e deve ser trocado.

Dispersão entre equipes. A mesma Beta implica desvio-padrão de 0,7 a 0,9 no logito entre unidades. A Secretaria relatou que a variação entre equipes da mesma unidade é maior que a variação entre unidades. O valor de 0,5 proposto na Etapa 5 contradiz esse relato. A proposta é usar $\sigma_{\mathrm{v}} = 1{,}0$ como valor central e 0,5 e 1,5 como cenários. Na escala latente, as correlações intraclasse correspondentes são 0,07, 0,23 e 0,41, calculadas por $\sigma^2/(\sigma^2 + \pi^2/3)$. Esse parâmetro não é identificável a partir de totais por unidade, que só informam a média de cada USF. Ele só pode ser estimado com dados por equipe. Por isso fica como premissa até que a Secretaria forneça ao menos um distrito com recorte por INE.

Ausência não aleatória. Na taxonomia de Rubin (1976) e de Little e Rubin (2019), a falta de resposta é MNAR quando depende do próprio valor ausente. Aqui isso ocorre quando $\lambda \neq 0$: pessoas LGB+ aceitam informar com chance diferente das heterossexuais. Os estudos de classe C (Souza, 2018) sugerem λ negativo, por medo de exposição e por experiência de discriminação, mas não há estimativa numérica. O cenário central é $\lambda = 0$. Os cenários de sensibilidade usam razões de chances de 0,5 e 1,5. É esse parâmetro que permite à Etapa 10 medir o viés da prevalência ingênua entre quem informou.

```
# Listagem 2 – registro em duas etapas (vetorizado); códigos: 1 Sim, 0 Não, -1 não informado
def registra_os(rng, idade, lgb, eta_r, eta_a, p):
    n = idade.size
    perguntado = rng.random(n) < expit(eta_r + p.kappa * (idade < p.idade_min))
    aceita = rng.random(n) < expit(eta_a + p.f_idade(idade) + p.lam * lgb)
    nao_sem_pergunta = rng.random(n) < p.pi            # cenário da pergunta 10
    deseja = np.full(n, -1, dtype=np.int8)
    deseja[perguntado] = aceita[perguntado]
    deseja[~perguntado & nao_sem_pergunta] = 0
    return deseja      # eta_r e eta_a já somam USF, equipe, tendência e oficina
```

Demais quesitos. A cor ou raça registrada depende de um regime de classificação da equipe, de autodeclaração ou de heteroidentificação, sorteado aqui e gravado em `verdade/`. A Etapa 7 aplica sobre ele as matrizes de erro (excesso de “branca” ou de “amarela”), registrando cada troca no gabarito. A deficiência registrada depende da verdadeira por uma sensibilidade de registro (premissa de 0,5 a 0,9), porque o conceito funcional do Censo não coincide com o que a equipe pergunta, e por uma pequena taxa de falso positivo.

Verificação. Proporções de Sim, Não e não informado por USF iguais às metas dentro da tolerância; variância entre equipes da mesma unidade igual à premissa; proporções das crianças compatíveis com a planilha no cenário de π escolhido.

4.6 Passo 6 – Dinâmica no tempo

Método. O tempo é discreto, com 45 competências mensais de janeiro de 2023 a setembro de 2026. Cada componente usa um processo estocástico padrão:

- **Equipes novas:** entram nas datas de ativação do CNES. O cadastro cresce por uma curva logística, $N_e(t) = K_e/[1 + e^{-r(t - t_0)}]$, com velocidade r de premissa. Equipes novas começam com cadastro pequeno, o que importa para o problema de regressão.
- **Nascimentos:** processo de Poisson mensal por DS e raça da mãe, com média tirada do SINASC de 2024 (16.120 nascidos vivos). O cadastro da criança entra com atraso sorteado.
- **Óbitos:** taxas específicas por idade e raça, $m_{a,r} = D_{a,r}/P_{a,r}$, com óbitos do SIM de 2024 (boletim da SESAU, Tabela 4) e população do Censo (9606), convertidas em risco mensal por $h = 1 - (1 - q)^{1/12}$. As taxas brutas do boletim (9,0 por mil em negros e 9,8 em não-negros) não servem para isso: a população não-negra é mais velha, e só as taxas por idade evitam o paradoxo de Simpson.
- **Mudança de território:** cadeia de Markov mensal com os estados ativo, mudou com registro de saída, mudou sem registro (cadastro desatualizado, alimenta a RQ06) e óbito. A taxa anual de mudança é premissa, de 5% a 10%.
- **Novas versões do cadastro:** processo de renovação com intervalo geométrico entre atualizações e taxa própria de cada equipe. A cada versão, os estágios R e A são sorteados de novo, com o mesmo w_i da pessoa.
- **Tendência das equipes:** inclinação $\tau_e \sim N(0, \sigma^2_\tau)$ somada a choques AR(1) no logito, $\eta_{e,t} = \varphi\eta_{e,t-1} + \varepsilon_{e,t}$.
- **Oficinas:** desenho de adoção escalonada, com datas e equipes sorteadas e efeitos γ_R e γ_A de 0, 0,2 ou 0,5 no logito, com decaimento opcional. Com 30% de Sim na linha de base, os efeitos levam a 34,4% e 41,4%. Há duas regras de alocação. Na aleatória, as oficinas vão para equipes sorteadas. Na focalizada, vão para as equipes de pior desempenho, como a gestão faria. A focalizada cria um problema real: a regressão à média faz a comparação in-

gênua de antes e depois superestimar o efeito, e só métodos de diferenças em diferenças com adoção escalonada o corrigem (Callaway; Sant'Anna, 2021).

Verificação. Todas as equipes ativas presentes em todas as competências; nascimentos e óbitos anuais compatíveis com o SINASC e o SIM, à escala; numa execução sem ruído, diferença de logito antes e depois da oficina igual a γ.

4.7 Passo 7 – Atendimentos

Método. O número de atendimentos da pessoa *i* no mês *t* segue um modelo de contagem com sobredispersão e excesso de zeros. Um estágio de barreira (*hurdle*) separa quem não usa o serviço, e o restante segue uma binomial negativa, isto é, uma mistura Poisson–Gama (Cameron; Trivedi, 2013):

$$\log \mu_{it} = \beta_0 + f(\text{idade, sexo}) + \beta_D \cdot \text{deficiência}^* + \Sigma_g \log \text{RR}_g \cdot \text{grupo}_g + \text{oferta}_e + \text{sazonalidade}_{\text{mês}}.$$

Enquanto a produção do SISAB por equipe (pendência F5) não for coletada, β_0 e *f* são premissas de ordem de grandeza. As razões de utilização RR_g são premissas com direção sustentada por evidência:

- para a população LGBTQIAPN+, abaixo de 1, pelo vínculo de 45% em Souza (2018);
- para pessoas com deficiência, intervalo nos dois sentidos, por necessidade maior e barreiras maiores (Farias *et al.*, 2023);
- para a população negra, valor central 1, a separar no pré-natal.

No pré-natal a calibração é direta e de classe A. O boletim da SESAU dá a distribuição de consultas por raça da mãe. Entre negras, 2,1% não fizeram nenhuma consulta e 72,6% fizeram sete ou mais. Entre não-negras, foram 1,4% e 82,9%. Isso dá razões de 1,50 para nenhuma consulta e 0,88 para sete ou mais. As gestantes geradas a partir dos nascimentos do passo 6 recebem consultas sorteadas dessa distribuição multinomial, com CIAP2 W78 e CID-10 Z34 coerentes com a VC07 do modelo lógico. Os demais problemas e condições vêm de uma distribuição multinomial por faixa etária e sexo, suavizada por uma priori de Dirichlet para não zerar categorias raras. O atraso de digitação segue uma distribuição geométrica com média própria da equipe e alimenta a RQ08.

Verificação. Distribuição de consultas de pré-natal por raça dentro de 1 ponto percentual da do boletim; razão de atendimentos por cadastrado compatível com o SISAB quando a pendência F5 for resolvida; regras VC06 e VC07 sem violação.

4.8 Passo 8 – Identificadores e textos

Nomes e endereços vêm do Faker com localidade `pt_BR`, com semente própria. O CPF é gerado com os dois dígitos verificadores de módulo 11. O CNS segue a regra do Ministério da Saúde: o definitivo começa por 1 ou 2, o provisório por 7, 8 ou 9, e a soma ponderada dos 15 dígitos (pesos de 15 a 1) é divisível por 11. A unicidade é garantida por conjunto de controle. O plano diz que os números não têm “correspondência com pessoas reais”, mas isso não pode ser garantido. A Receita Federal já emitiu centenas de milhões de CPFs num espaço de um bilhão de números-base, de modo que um CPF válido sorteado tem probabilidade não desprezível de pertencer a alguém. O risco é baixo, porque nenhum atributo real está associado ao número. Ainda assim, a versão pública do banco deve trocar CPF e CNS por chaves substitutas, ou ser distribuída como código mais semente, e nunca deve ser cruzada com dado real. A duplicidade intencional de pessoas é defeito da Etapa 7.

5 INCERTEZA E ANÁLISE DE SENSIBILIDADE

O banco tem dois tipos de incerteza, que não devem ser confundidos. A incerteza aleatória vem do próprio sorteio e é medida por réplicas com sementes diferentes. Com R réplicas, o erro-padrão de Monte Carlo de uma média é DP/√R, e R é escolhido para que esse erro fique abaixo de um décimo do efeito de interesse (Morris; White; Crowther, 2019). A incerteza epistêmica vem do desconhecimento dos parâmetros de premissa e é tratada por cenários. Os parâmetros discretos ou que mudam a interpretação variam um de cada vez, a partir do cenário base (Tabela 7). Os contínuos são explorados juntos por amostragem em hipercubo latino (McKay; Beckman; Conover, 1979), com 50 execuções a 5% de escala. A influência de cada premissa sobre as saídas é resumida pelo coeficiente de correlação parcial de postos (Marino *et al.*, 2008).

Tabela 7 – Fatores da análise de sensibilidade

Fator	Base	Cenários	Saída mais afetada
Dispersão entre equipes σ_v (logito)	1,0	0,5; 1,5	Ranqueamento; ganho do encolhimento
Semântica do “Não” (π)	0	0,5; 0,9	Leitura do indicador; reprodução das crianças
Ausência não aleatória (razão de chances LGB+)	1,0	0,5; 1,5	Viés da prevalência ingênua
Efeito da oficina γ (logito)	0,2	0; 0,5	Recuperação do efeito
Alocação das oficinas	aleatória	focalizada	Viés do antes e depois
Cobertura municipal	80%	75%; 90%	Denominadores
Efeito da raça e da renda no cadastro (β)	direção da evidência	β = 0	Desigualdade de cobertura
Sensibilidade do registro de deficiência	0,7	0,5; 0,9	Prevalência registrada
Razão de natalidade r (raça por DS)	1,71	±15%	Raça por DS

Fonte: elaborado pelo grupo.

6 VALIDAÇÃO DO GERADOR

A validação da Etapa 6 ocorre em memória, antes da carga no SGBD, e gera um relatório de calibração a cada execução. A Etapa 8 repete a conferência no banco. Três decisões de método orientam o relatório.

Tolerância proporcional à escala. O plano propõe tolerância de ±1 ponto percentual. Isso é adequado no município inteiro, mas não numa equipe nem com fator de escala pequeno. Para uma proporção de 30% numa equipe com 2.500 elegíveis, o erro-padrão binomial é 0,9 ponto. A 10% de escala, com 250 elegíveis, ele sobe para 2,9 pontos. O critério adotado é $|\hat{\theta} - \theta| \leq \max(\delta; 3 \cdot EP)$, em que $\delta = 1$ ponto percentual e EP é o erro-padrão binomial na escala da execução.

Equivalência, e não significância. Com 1,2 milhão de cadastrados, qualquer diferença trivial seria estatisticamente significativa num teste qui-quadrado. Com amostra pequena, diferenças grandes passariam. O teste de hipótese nula de igualdade não responde à pergunta da validação, que é se o banco está perto o bastante da meta. Por isso a validação usa teste de equivalência com dois testes unilaterais (TOST; Schuirmann, 1987) e margem δ, além de distâncias com limiar declarado. A distância de variação total e a de Hellinger servem para distribuições inteiras, como a pirâmide etária e a cor ou raça por equipe. O qui-quadrado entra só como descritivo, acompanhado do V de Cramér.

Estrutura, além das marginais. Bater as marginais não garante a estrutura conjunta. O relatório inclui, por isso, três verificações estruturais. A primeira são testes de independência condicional implicados pelo DAG, como OS* ⊥ raça | idade, executados como testes unitários. A segunda é a preservação das razões de chances da semente do IPF. A terceira são testes de recuperação: numa

execução sem ruído, os efeitos estimados devem coincidir com os gravados em `verdade/`. Numa execução com ruído, um modelo misto ajustado ao banco deve recuperar σ_v e γ dentro do erro de Monte Carlo. A reprodutibilidade é conferida pelo hash dos arquivos, e a plausibilidade, pela leitura da planilha reproduzida pela Secretaria na validação de 21/11.

7 ARQUITETURA DO PACOTE PYTHON

O pacote espelha os oito passos, e o DAG é declarado no próprio código. Cada nó é uma função que informa os seus pais e a fonte de cada parâmetro. O `networkx` confere se o grafo é acíclico e fornece a ordem topológica de geração. A mesma declaração gera automaticamente o Apêndice B do *data card*, o que impede que documentação e código divirjam.

Tabela 8 – Módulos do pacote e bibliotecas

Módulo	Responsabilidade	Bibliotecas
`config/`	Cenário base e cenários em YAML: semente, escala, DS, data de corte, premissas	PyYAML, pydantic
`rng.py`	Fluxos aleatórios independentes por módulo e DS, gerados com `SeedSequence.spawn`	numpy (PCG64)
`parametros.py`	Leitura e validação dos CSV da Etapa 5 e do registro de premissas	pandas
`territorio.py`, `populacao.py`	Passos 1 e 2: estrutura, IPF, TRS, domicílios	numpy, scipy
`cobertura.py`, `atributos.py`	Passos 3 e 4: calibração de interceptos, cópulas	scipy (`optimize`, `stats`)
`registro.py`, `dinamica.py`	Passos 5 e 6: modelo misto, Gauss–Hermite, cadeias de Markov, oficinas	numpy, scipy
`atendimentos.py`, `identificadores.py`	Passos 7 e 8	numpy, Faker
`exporta.py`	*Staging* no formato LEDI (CSV ou Parquet), `verdade/`, manifesto com SHA-256	pyarrow
`valida.py`, `sensibilidade.py`	Relatório de calibração (seção 6); hipercubo latino e correlação parcial de postos	scipy (`stats.qmc`), matplotlib
`tests/`	Testes unitários: DV de CPF e CNS, independências do DAG, regras do LEDI, reprodutibilidade	pytest, hypothesis

Fonte: elaborado pelo grupo.

Gerar por DS, com um fluxo aleatório próprio para cada DS, tem duas vantagens: permite executar em paralelo e permite gerar um distrito isolado para testes sem mudar o resultado dos demais. O volume total é de ordem de grandeza tratável num computador pessoal. São cerca de 1,5 milhão de residentes e 1,2 milhão de cadastrados. A premissa de uma atualização a cada 18 meses dá algo como 3 milhões de versões de cadastro. A premissa de 2 a 3 atendimentos por cadastrado ao ano dá entre 10 e 15 milhões de atendimentos em 45 meses. Essas contagens cabem em vetores numpy com tipos compactos, gravados por distrito em Parquet. Para o desenvolvimento, o fator de escala de 5% a 10% basta. O município inteiro é gerado só nas execuções de entrega.

8 VIABILIDADE

A Tabela 9 avalia cada passo pela disponibilidade dos dados, pela complexidade do método e pela alternativa caso o dado não chegue a tempo. Nenhum passo depende de dado indisponível sem ter alternativa declarada. Os pontos de maior risco são a formação de domicílios com homofilia (IPU) e a calibração por equipe, e ambos têm versão simplificada para o MVP.

Tabela 9 – Viabilidade por passo

Passo	Dados	Complexidade	Risco principal	Alternativa para o MVP
1 Território	Disponíveis (CNES, Censo, Prefeitura)	Baixa	Distrito de 10 bairros inferido (E5)	Usar a atribuição atual e marcar como premissa
2 População	Disponíveis; raça por DS derivada	Média	Composição racial dos domicílios	Domicílios por regra; IPU na Sprint 4
3 Cobertura	Parcial (SISAB pendente, E2)	Média	Meta por equipe ser a capacidade	Capacidade de 2.863 com teto por DS
4 Atributos	Disponíveis (Censo, PNS, Spizzirri)	Média	Ligação escolaridade × renda	Cópula com ρ de premissa
5 Registro	Planilha não autorizada; π desconhecido	Alta	Parâmetros não identificáveis	Priori Beta(2,9; 10,7) e cenários de π
6 Dinâmica	Disponíveis (CNES, SINASC, SIM); oficinas desconhecidas	Alta	Interação entre processos	Começar só com equipes, óbitos e versões
7 Atendimentos	Parcial (SISAB pendente, F5); pré-natal disponível	Média	Volume e taxa média	Taxas de premissa; pré-natal calibrado
8 Identificadores	Não dependem de dados	Baixa	Colisão com CPF real	Chaves substitutas na versão pública

Fonte: elaborado pelo grupo.

O plano já reconhece o gerador com série temporal como caminho crítico. A Tabela 10 distribui o trabalho pelas entregas restantes, respeitando o que o cronograma do plano espera de cada uma. Para a Sprint 2, o piloto é o DS I, o menor em população (73.764 residentes, 10 unidades e 23 equipes). O DS VIII, com cobertura perto de 100% e maior proporção de pretos e pardos, serve de segundo teste antes de escalar.

Tabela 10 – Cronograma da Etapa 6

Entrega	Conteúdo
24/10 – Sprint 2	`rng`, `config`, `parametros`; passos 1 e 2 para o DS I (IPF com raça por DS, TRS, domicílios por regra); primeiro relatório de calibração
25/10 a 31/10	Passos 3, 4, 5 e 8; cenário base; testes de DV e de independência condicional; DS VIII como segundo teste
01/11 a 07/11 – Sprint 3	Passos 6 e 7; exportação para a *staging* e `verdade/`; município a 10% e a 100%; cenários de π e de alocação das oficinas; entrega para as Etapas 7, 8 e 10
08/11 a 14/11 – Sprint 4	Hipercubo latino com 50 execuções; testes de recuperação para a Etapa 10; IPU, se houver tempo

Fonte: elaborado pelo grupo a partir da Tabela 11 do plano v3.

Do ponto de vista das competências, os métodos usam bibliotecas que o curso já mobiliza (numpy, pandas, scipy) e têm implementação curta, como mostram as Listagens 1 e 2. As partes mais delicadas, a calibração por quadratura e a cópula, já foram testadas pelo grupo nos cálculos deste documento: a correção de atenuação, a correlação ρ = 0,65 da deficiência e a Beta das unidades.

9 LIMITAÇÕES E CUIDADOS ÉTICOS

A limitação principal é de natureza: o banco reproduz o que foi publicado e o que foi suposto. Modelos treinados nele aprendem as relações programadas, e qualquer resultado da Etapa 10 é demonstração de método, não afirmação sobre a população do Recife. Os parâmetros de premissa, como σ_v, π, λ, γ e as razões de utilização, não são identificáveis com os dados disponíveis. A análise de sensibilidade mostra quanto as conclusões dependem deles, mas não os estima. A estimativa de raça por DS depende de premissas declaradas e deve dar lugar aos agregados por setor censitário assim que forem coletados (pendência E6).

Três cuidados éticos se somam aos do plano. O primeiro é a associação entre marcadores sociais. Toda aresta do DAG que liga raça, orientação sexual, identidade de gênero ou deficiência a outra variável tem fonte citada no Apêndice B. Onde a evidência é fraca, o cenário central é de independência, e a hipótese de associação fica como cenário de sensibilidade, nunca como valor padrão. O segundo é a natureza dos atributos latentes. A orientação sexual e a identidade de gênero "verdadeiras" existem só como recurso de simulação, para medir o viés do registro. Nenhum produto do projeto deve sugerir que esses atributos possam ser inferidos de alguém, o que a salvaguarda da Etapa 10 já proíbe. O terceiro são os estudos de classe C. Eles dão voz a experiências de discriminação e foram usados para orientar a direção dos cenários. Não foram usados como taxas populacionais, porque isso ultrapassaria o que o seu desenho permite afirmar.

10 CONSIDERAÇÕES FINAIS

A Etapa 6 deixa de ser uma lista de passos e passa a ser um modelo probabilístico declarado. Esse modelo combina um DAG, efeitos aleatórios por nível hierárquico, processos estocásticos para o tempo e um mecanismo explícito de observação, que separa o atributo verdadeiro do registrado. Cada passo tem método, fonte e critério de verificação. Os documentos acrescentados ao projeto trouxeram quatro contribuições concretas:

- uma marginal de cor ou raça por Distrito Sanitário, validada contra o Censo no total do município;
- uma meta de pré-natal por raça, de classe A;
- uma escala de completude para classificar o registro;
- a demonstração de que a semântica do "Não" muda a leitura do indicador principal e não pode ser decidida pelos agregados.

Esse último ponto e a dispersão entre equipes são as duas perguntas que a Secretaria precisa responder para que o banco sintético se aproxime do comportamento real das equipes. Com as alternativas declaradas para os dados pendentes, o gerador completo cabe no prazo da Sprint 3 e entrega às etapas seguintes o que elas exigem: um banco calibrado, um gabarito de verdade conhecida e um conjunto de cenários que mostra quanto as conclusões dependem das premissas.

REFERÊNCIAS

BECKMAN, R. J.; BAGGERLY, K. A.; McKAY, M. D. Creating synthetic baseline populations. *Transportation Research Part A*, v. 30, n. 6, p. 415-429, 1996.

BISHOP, Y. M. M.; FIENBERG, S. E.; HOLLAND, P. W. *Discrete multivariate analysis*: theory and practice. Cambridge, MA: MIT Press, 1975.

BRASIL. Ministério da Saúde. Portaria n.º 2.488, de 21 de outubro de 2011. Aprova a Política Nacional de Atenção Básica. *Diário Oficial da União*, Brasília, 2011.

CALLAWAY, B.; SANT'ANNA, P. H. C. Difference-in-differences with multiple time periods. *Journal of Econometrics*, v. 225, n. 2, p. 200-230, 2021.

CAMERON, A. C.; TRIVEDI, P. K. *Regression analysis of count data*. 2. ed. Cambridge: Cambridge University Press, 2013.

CSISZÁR, I. I-divergence geometry of probability distributions and minimization problems. *The Annals of Probability*, v. 3, n. 1, p. 146-158, 1975.

DEMING, W. E.; STEPHAN, F. F. On a least squares adjustment of a sampled frequency table when the expected marginal totals are known. *The Annals of Mathematical Statistics*, v. 11, n. 4, p. 427-444, 1940.

DRECHSLER, J. *Synthetic datasets for statistical disclosure control*. New York: Springer, 2011.

EMRICH, L. J.; PIEDMONTE, M. R. A method for generating high-dimensional multivariate binary variates. *The American Statistician*, v. 45, n. 4, p. 302-304, 1991.

EQUIPE 2 – NEXUS DATA. *Emulação de dados da Atenção Primária à Saúde para as políticas de equidade do Recife*: plano de dados sintéticos calibrados em fontes oficiais, v3. Recife: CESAR School, 2026. Documento interno.

EQUIPE 2 – NEXUS DATA. *Parâmetros oficiais*: Etapa 5, v1.0.0; *Modelo lógico*: Etapa 3, v1.0.0. Recife: CESAR School, 2026. Documentos internos.

FARIAS, T. M. O. *et al.* O estreito acesso das pessoas com deficiência aos serviços de saúde em uma capital nordestina. *Ciência & Saúde Coletiva*, v. 28, n. 5, p. 1539-1548, 2023.

GEBRU, T. *et al.* Datasheets for datasets. *Communications of the ACM*, v. 64, n. 12, p. 86-92, 2021.

GELMAN, A.; HILL, J. *Data analysis using regression and multilevel/hierarchical models*. Cambridge: Cambridge University Press, 2007.

GONZAGA, V. Proposta de criação de ambulatório LGBTQIA+ é vetada na Câmara de Garanhuns, no Agreste de PE. *Brasil de Fato*, Recife, 18 abr. 2022. Disponível em: https://www.brasildefato.com.br/2022/04/18/proposta-de-criacao-de-ambulatorio-lgbtqia-e-vetada-na-camara-de-garanhuns-no-agreste-de-pe/. Acesso em: 22 out. 2026.

IBGE. *Censo Demográfico 2022*: tabelas 9514, 9605, 9606, 9922, 9923, 10061, 10125, 10127, 10132, 10145 e 10296. SIDRA. Disponível em: https://sidra.ibge.gov.br. Acesso em: 20 out. 2026.

IBGE. *Orientação sexual autoidentificada da população adulta*: Pesquisa Nacional de Saúde 2019. Rio de Janeiro: IBGE, 2022.

LITTLE, R. J. A.; RUBIN, D. B. *Statistical analysis with missing data*. 3. ed. Hoboken: Wiley, 2019.

LOVELACE, R.; BALLAS, D. 'Truncate, replicate, sample': a method for creating integer weights for spatial microsimulation. *Computers, Environment and Urban Systems*, v. 41, p. 1-11, 2013.

LOVELACE, R.; DUMONT, M. *Spatial microsimulation with R*. Boca Raton: CRC Press, 2016.

MARINO, S. *et al.* A methodology for performing global uncertainty and sensitivity analysis in systems biology. *Journal of Theoretical Biology*, v. 254, n. 1, p. 178-196, 2008.

McKAY, M. D.; BECKMAN, R. J.; CONOVER, W. J. A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, v. 21, n. 2, p. 239-245, 1979.

MORRIS, T. P.; WHITE, I. R.; CROWTHER, M. J. Using simulation studies to evaluate statistical methods. *Statistics in Medicine*, v. 38, n. 11, p. 2074-2102, 2019.

NELSEN, R. B. *An introduction to copulas*. 2. ed. New York: Springer, 2006.

OLIVEIRA, M. R. *et al.* Avaliação da completude do quesito raça/cor nos Sistemas Nacionais de Informação em Saúde, no município do Recife. *Brazilian Journal of Health Review*, v. 8, n. 1, p. 1-15, 2025. DOI: 10.34119/bjhrv8n1-173.

PEARL, J. *Causality*: models, reasoning, and inference. 2. ed. Cambridge: Cambridge University Press, 2009.

RECIFE. Secretaria de Saúde. Secretaria Executiva de Vigilância em Saúde. Natalidade e mortalidade por raça/cor da pele. *Boletim Epidemiológico SSIS/GEVEPI/SEVS*, n. 1, 2025. Disponível em: https://cievsrecife.wordpress.com/publicacoes-devs-sesau-recife/. Acesso em: 22 out. 2026.

REICHENBERGER, V. *et al.* Access to primary healthcare services among adults with disabilities in Brazil. *Revista de Saúde Pública*, v. 58, 2024. DOI: 10.11606/s1518-8787.2024058005842.

ROMERO, D. E.; CUNHA, C. B. Avaliação da qualidade das variáveis socioeconômicas e demográficas dos óbitos de crianças menores de um ano registrados no Sistema de Informações sobre Mortalidade do Brasil (1996/2001). *Cadernos de Saúde Pública*, v. 22, n. 3, p. 673-684, 2006.

RUBIN, D. B. Inference and missing data. *Biometrika*, v. 63, n. 3, p. 581-592, 1976.

RUBIN, D. B. Discussion: statistical disclosure limitation. *Journal of Official Statistics*, v. 9, n. 2, p. 461-468, 1993.

SANTOS, E. J. V. S.; MELO, C. P. L. Caracterização e acesso aos cuidados em saúde de um serviço referência do processo transexualizador no SUS. *Research, Society and Development*, v. 11, n. 5, e13411527902, 2022. DOI: 10.33448/rsd-v11i5.27902.

SCHUIRMANN, D. J. A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. *Journal of Pharmacokinetics and Biopharmaceutics*, v. 15, n. 6, p. 657-680, 1987.

SNOKE, J. *et al.* General and specific utility measures for synthetic data. *Journal of the Royal Statistical Society: Series A*, v. 181, n. 3, p. 663-688, 2018.

SOUZA, A. C. J. *Análise sobre acesso e qualidade da atenção integral à saúde de mulheres lésbicas, bissexuais, transexuais e travestis na Atenção Básica de Saúde na cidade do Recife, Brasil*. 2018. 200 f. Tese (Doutorado em Saúde Pública) – Instituto Aggeu Magalhães, Fundação Oswaldo Cruz, Recife, 2018.

SPIZZIRRI, G. *et al.* Proportion of people identified as transgender and non-binary gender in Brazil. *Scientific Reports*, v. 11, n. 1, 2021. DOI: 10.1038/s41598-021-81411-4.

TILLÉ, Y. *Sampling algorithms*. New York: Springer, 2006.

WILLIAMSON, P.; BIRKIN, M.; REES, P. H. The estimation of population microdata by using data from small area statistics and samples of anonymised records. *Environment and Planning A*, v. 30, n. 5, p. 785-816, 1998.

YE, X. *et al.* A methodology to match distributions of both household and person attributes in the generation of synthetic populations. In: TRANSPORTATION RESEARCH BOARD ANNUAL MEETING, 88., 2009, Washington. *Proceedings* […]. Washington: TRB, 2009.

ZEGER, S. L.; LIANG, K.-Y.; ALBERT, P. S. Models for longitudinal data: a generalized estimating equation approach. *Biometrics*, v. 44, n. 4, p. 1049-1060, 1988.

APÊNDICE A – REGISTRO DE PARÂMETROS NOVOS OU REVISTOS

A tabela complementa a Tabela 6 do plano e o arquivo `premissas_gerador.csv` da Etapa 5. Só aparecem os parâmetros criados ou alterados por este documento.

Parâmetro	Valor central	Intervalo ou cenários	Classe	Fonte ou justificativa
Pretos e pardos por DS	Tabela 4	$r \pm 15\%$	B	RECIFE (2025), estimador indireto validado no município
Razão de natalidade negras / não-negras (r)	1,71	1,45 a 1,96	A/B	RECIFE (2025): 12,8 e 7,5 por mil
Priori das USF para “Deseja informar OS” = Sim	Beta(2,9; 10,7)	média 21%	B	Faixa de 3% a 53% em 144 unidades; substitui o ponto médio de 28%
Dispersão entre equipes σ_v (logito)	1,0	0,5; 1,5	premissa	σ_{USF} implícito de 0,7 a 0,9; relato da SESAU
Probabilidade de “Não” sem pergunta (π)	0	0,5; 0,9	premissa	Não identificável (Tabela 5); pergunta 10 do Apêndice A do plano
Efeito de ser criança na pergunta (κ)	calibrado	conforme π	A	Linha da planilha: 10,0% Sim, 87,3% Não, 2,7% NI
Razão de chances de aceitação LGB+ (e^{λ})	1,0	0,5; 1,5	C	Direção negativa sugerida por Souza (2018)
Correlação entre tipos de deficiência (ρ)	0,65	0,57 a 0,72	A	Calibrada para a união de 8,39% (Censo 2022)
Sensibilidade do registro de deficiência	0,7	0,5 a 0,9	premissa	Conceito funcional do Censo diferente da pergunta do e-SUS
Omissão de morador em domicílio cadastrado	2%	1% a 3%	premissa	—
Microáreas por equipe	$\lceil N_e/750 \rceil$	máximo de 12	A	PNAB (BRASIL, 2011)
Consultas de pré-natal por raça (0; 1–3; 4–6; 7+)	negras: 2,1; 6,3; 19,0; 72,6%	não-negras: 1,4; 3,4; 12,4; 82,9%	A	RECIFE (2025), Tabela 1
Mudança de território (anual)	7,5%	5% a 10%	premissa	—
Alocação das oficinas	aleatória	focalizada	premissa	Teste de viés por regressão à média
Razões de utilização (LGBTQIAPN+; PcD)	1,0	0,7 a 1,0; 0,8 a 1,3	C	Souza (2018); Farias *et al.* (2023)

Fonte: elaborado pelo grupo.

APÊNDICE B – ARESTAS DO DAG E FONTES

Aresta	Tipo	Fonte
Território → cor ou raça	calibrada	IPF com raça por DS (Tabela 4); setor censitário quando houver (E6)
Idade, sexo, raça → escolaridade	calibrada	Censo, tab. 10061
Raça, sexo → renda familiar	calibrada	Censo, tab. 10296
Escolaridade ↔ renda	premissa	Cópula com ρ de premissa até a PNAD (E7)
Idade, sexo, raça → deficiência	calibrada	Censo, tab. 10125 e 10132
Deficiência → tipos	calibrada	Censo, tab. 10127; Tabela 7 do plano
Idade, sexo → TEA	calibrada	Censo, tab. 10145
Idade, sexo → OS*	literatura	PNS 2019 (gradiente etário nacional aplicado à taxa de PE)
Idade → IG*	premissa	Direção: Santos e Melo (2022); nível: Spizzirri *et al.* (2021)

Território, renda, raça → cadastro	calibrada / premissa	Capacidade do CNES; direção do boletim da SESAU; PNS 2019 (E8)
Equipe, USF → perguntado, aceita	calibrada / premissa	Planilha da SESAU (médias por USF); σ_v de premissa
Idade → perguntado (criança)	calibrada	Planilha da SESAU (linha das crianças)
Idade → aceita	literatura	PNS 2019 (recusa e “não sabe” por idade)
OS* → aceita (λ)	premissa	Direção: Souza (2018)
Oficina → perguntado, aceita (γ)	premissa	Verdade conhecida (Tabela 6 do plano)
Idade, sexo, deficiência, grupos → atendimentos	premissa / calibrada	SISAB (F5); pré-natal: RECIFE (2025); direção: Souza (2018), Farias *et al.* (2023)
Ausência: raça → OS*; raça → IG*	sem aresta	PNS 2019 sem diferença por raça; sem dado para IG

Fonte: elaborado pelo grupo. No pacote, esta tabela é gerada a partir da declaração do DAG no código (seção 7).